

Validació i optimització d'una signatura molecular predictiva de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble



Universitat
Oberta
de Catalunya

Joan Carreras Díaz

Màster Universitari en
Bioinformàtica i Bioestadística
Desenvolupament de
Programari i Aplicacions

Tutor/a de TF

[Teresa Torres Moral](#)

**Professor/a responsable de
l'assignatura**

Marta Gatnau Sarret

Juny 2026

FITXA DEL TREBALL FINAL

Títol del treball:	<i>Validació i optimització d'una signatura molecular predictiva de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble</i>
Nom de l'autor:	<i>Joan Carreras Díaz</i>
Nom del director/a:	<i>Marta Gatnau Sarret</i>
Nom del PRA:	<u>Teresa Torres Moral</u>
Data de lliurament (mm/aaaa):	<i>06/2026</i>
Titulació o programa:	<i>Màster Universitari en Bioinformàtica i Bioestadística</i>
Àrea del Treball Final:	<i>Desenvolupament de Programari i Aplicacions</i>
Idioma del treball:	<i>Català</i>
Paraules clau	<i>Immunotherapy response, Melanoma, Transcriptomic signature, Machine learning, Reproducible bioinformatics pipeline</i>
Resum del Treball	
Aquest Treball Final de Màster té com a objectiu desenvolupar i validar un pipeline bioinformàtic reproduïble per a la predicció de la resposta a immunoteràpia anti-PD-1 en melanoma mitjançant dades transcriptòmiques. L'estudi s'emmarca en el context de la medicina de precisió, on la identificació de biomarcadors moleculars pot contribuir a optimitzar la selecció de pacients candidats a immunoteràpia. El pipeline es va implementar en R i integra la càrrega i harmonització de dades públiques, el preprocessament transcriptòmic, la selecció de variables, la modelització predictiva i la validació interna i externa. Es va utilitzar GSE160638 com a cohort d'entrenament, mentre que GSE91061 i GSE78220 es van emprar com a cohorts independents de validació externa. La variable clínica de resposta es va harmonitzar segons criteris RECIST i es va prioritzar l'ús de mostres pre-treatment. El model final es va basar en una signatura de 100 gens i un algoritme Random Forest, amb selecció de variables dins de cada fold per evitar data leakage. En validació interna, el model va mostrar una capacitat discriminativa moderada-alta, mentre que en validació externa va obtenir un rendiment moderat, amb AUC de 0,671 en GSE91061 i 0,611 en GSE78220.	

Els resultats indiquen que el pipeline és robust, traçable i reproduïble, però també evidencien les limitacions associades a l'heterogeneïtat entre cohorts i a la mida mostral reduïda. El model s'ha d'interpretar com una prova de concepte amb potencial translacional, però no com una eina clínica immediata.

Abstract

This Master's Thesis aims to develop and validate a reproducible bioinformatics pipeline for predicting response to anti-PD-1 immunotherapy in melanoma using transcriptomic data. The work is framed within precision medicine, where the identification of molecular biomarkers may help optimize the selection of patients most likely to benefit from immunotherapy.

The pipeline was implemented in R and integrates public data acquisition and harmonization, transcriptomic preprocessing, feature selection, predictive modelling, and internal and external validation. GSE160638 was used as the training cohort, while GSE91061 and GSE78220 were used as independent external validation cohorts. Clinical response was harmonized according to RECIST criteria, and pre-treatment samples were prioritized to ensure a clinically realistic predictive scenario.

The final model was based on a 100-gene signature and a Random Forest algorithm, with feature selection performed within each cross-validation fold to prevent data leakage. In internal validation, the model showed moderate-to-high discriminative ability, whereas external validation showed moderate performance, with AUC values of 0.671 in GSE91061 and 0.611 in GSE78220.

Overall, the results demonstrate that the proposed pipeline is robust, traceable and reproducible. However, they also highlight important limitations related to inter-cohort heterogeneity, limited sample size and variability in external datasets. Therefore, the model should be interpreted as a proof of concept with translational potential, but not as an immediately applicable clinical decision-support tool.

Índex

1. INTRODUCCIÓ	6
1.1. CONTEXT I JUSTIFICACIÓ	6
1.2. OBJECTIUS DEL TREBALL	6
1.2.1. Objectiu principal	6
1.2.2. Objectius específics	6
1.3. IMPACTE ÈTIC, SOCIAL I DE SOSTENIBILITAT	7
1.3.1. Impacte clínic i social	7
1.3.2. Aspectes ètics i privacitat de les dades	8
1.3.3. Biaixos i limitacions del model	8
1.3.4. Limitacions ètiques del model	9
1.3.5. Sostenibilitat	9
1.3.6. Consideracions finals	9
1.4. ENFOCAMENT I MÈTODE	10
1.5. PLANIFICACIÓ	10
1.6. PRODUCTES OBTINGUTS	11
1.7. ESTRUCTURA DE LA MEMÒRIA	11
1.8. ASPECTES FORMALS	12
2. ESTAT DE L'ART	12
3. MATERIALS I MÈTODES	14
3.1. ANÀLISI DE REQUERIMENTS	14
3.1.1. Requeriments funcionals	14
3.1.2. Requeriments no funcionals	14
3.1.3. Entrades i sortides del sistema	15
3.1.4. Restriccions del sistema	15
3.1.5. Priorització dels requeriments	15
3.2. DISSENY DEL SISTEMA	16
3.2.1. Visió general del sistema	16
3.2.2. Arquitectura del pipeline	17
3.2.3. Descripció modular del sistema	17
3.2.4. Flux de dades	18
3.2.5. Propietats del disseny	18
3.3. DATASETS UTILITZATS	19
3.3.1. GSE160638	19
3.3.2. GSE91061	19
3.3.3. GSE78220	20
3.4. HARMONITZACIÓ CLÍNICA	20
3.4.1. Definició de responders i non-responders (RECIST)	20
3.4.2. Control del moment temporal (pre-treatment)	21
3.5. PREPROCESSAMENT TRANSCRIPTÒMIC	22
3.5.1. Filtrat	22
3.5.2. Normalització (TMM + logCPM)	22
3.6. ESTRATÈGIA DE MODELITZACIÓ	23
3.6.1. Model Random Forest	23
3.6.2. Justificació del model	23

3.7. ESTRATÈGIA DE VALIDACIÓ	24
3.7.1. <i>CV inicial</i>	24
3.7.2. <i>Correcció data leakage</i>	24
3.7.3. <i>Validació creuada anidada (Nested CV)</i>	24
3.8. SELECCIÓ DE VARIABLES	25
3.8.1. <i>DE genes</i>	25
3.8.2. <i>Comparació 50/100/250/500</i>	26
3.9. VALIDACIÓ EXTERNA	26
3.9.1. <i>Preparació datasets</i>	26
3.9.2. <i>Intersecció de gens</i>	27
3.10. MÈTRQUES D'AVUACIÓ	27
3.10.1. <i>AUC</i>	27
3.10.2. <i>Accuracy</i>	27
3.10.3. <i>Balanced accuracy</i>	27
3.10.4. <i>Sens / Spec</i>	28
4. RESULTATS	28
4.1. RESULTATS PRELIMINARS (PIPELINE INICIAL)	28
4.2. CORRECCIÓ DEL DATA LEAKAGE	29
4.3. MODEL FINAL (250 GENS → 100 GENS)	30
4.4. ESTABILITAT DE LA SIGNATURA	31
4.5. INTERPRETACIÓ BIOLÒGICA	33
4.5.1. <i>Interpretació crítica dels processos identificats</i>	34
4.6. VALIDACIÓ EXTERNA	35
4.6.1. <i>Resultats del model final (100 gens)</i>	35
4.6.2. <i>Comparació amb la signatura de 250 gens</i>	38
4.7. ANÀLISI DE LA CALIBRACIÓ	39
4.8. RESULTATS FINALS I COMPARATIVA	39
5. DISCUSSIÓ	39
5.1. COMPLIMENT DELS OBJECTIUS	39
5.2. COMPLIMENT DELS RESULTATS	41
5.2.1. <i>Resultats en validació interna</i>	41
5.2.2. <i>Impacte de la correcció del data leakage</i>	41
5.2.3. <i>Impacte de la dimensionalitat de la signatura</i>	41
5.2.4. <i>Resultats en validació externa</i>	42
5.2.5. <i>Anàlisi del comportament del model</i>	42
5.2.6. <i>Robustesa i estabilitat de la signatura</i>	42
5.2.7. <i>Conclusió global dels resultats</i>	42
5.3. COMPARACIÓ AMB LA LITERATURA	43
5.4. LIMITACIONS	45
5.5. IMPLICACIONS CLÍNQUES I ÈTIQUES	46
5.6. ROBUSTESA I REPRODUCTIBILITAT	47
6. CONCLUSIONS I TREBALL FUTUR	48
6.1. CONCLUSIONS	48
6.1.1. <i>Conclusió final</i>	49
6.2. APORTACIONS DEL TREBALL	49
6.2.1. <i>Aportacions metodològiques</i>	49
6.2.2. <i>Innovació del treball</i>	50

6.2.3. <i>Aportació global</i>	51
6.3. LIMITACIONS I TREBALL FUTUR	51
6.4. CONCLUSIÓ FINAL	52
7. Glossari	52
8. BIBLIOGRAFIA	54
<i>Articles científics</i>	54
<i>Metodologia bioinformàtica i estadística</i>	54
<i>Bases de dades utilitzades</i>	55
<i>Paquets i eines de software</i>	55
<i>Referències conceptuals</i>	55
9. ANNEXOS	56

1. Introducció

1.1. Context i justificació

La immunoteràpia basada en inhibidors de checkpoint (especialment anti-PD-1) ha suposat un avenç significatiu en el tractament del melanoma avançat. No obstant això, només una fracció dels pacients respon favorablement, fet que posa de manifest la necessitat de desenvolupar eines predictives que permetin identificar, de manera prèvia al tractament, aquells pacients amb major probabilitat de benefici clínic.

En aquest context, la bioinformàtica translacional i la medicina de precisió han impulsat l'estudi de biomarcadors moleculars, especialment basats en dades transcriptòmiques, com a possibles predictors de resposta terapèutica.

Tot i l'existència de múltiples signatures moleculars proposades a la literatura, la seva aplicabilitat clínica és encara limitada, principalment a causa de problemes de:

- Manca de validació externa robusta
- Baixa reproductibilitat entre cohorts
- Heterogeneïtat biològica i tècnica dels datasets

Aquest Treball Final de Màster s'emmarca en aquest repte i planteja la necessitat de **validar i optimitzar signatures moleculars en un entorn metodològicament rigorós i reproducible**, amb una orientació clara cap a la seva aplicació en contextos clínics reals.

1.2. Objectius del treball

1.2.1. Objectiu principal

Desenvolupar i validar un model predictiu robust de resposta a immunoteràpia en melanoma basat en dades transcriptòmiques, mitjançant un pipeline bioinformàtic reproducible i metodològicament rigorós, capaç de generalitzar en cohorts independents.

1.2.2. Objectius específics

Per assolir aquest objectiu principal, es defineixen els següents objectius específics, organitzats segons la seva prioritat metodològica:

(1) Construcció del pipeline reproducible

- Implementar un pipeline bioinformàtic complet en R que integri preprocessament, selecció de variables i modelització.
- Garantir la traçabilitat i reproductibilitat de tots els passos de l'anàlisi.

(2) Harmonització i preparació de dades

- Identificar i curar datasets públics de melanoma tractat amb immunoteràpia.

- Harmonitzar la variable de resposta clínica (responders / non-responders) segons criteris RECIST.
 - Controlar el moment temporal de les mostres (pre-treatment).
- (3) **Desenvolupament del model predictiu**
- Seleccionar gens rellevants mitjançant anàlisi d'expressió diferencial dins d'un esquema lliure de data leakage.
 - Entrenar models predictius multivariants basats en Random Forest.
 - Analitzar l'impacte de la dimensionalitat de la signatura (50, 100, 250 i 500 gens).
- (4) **Validació rigorosa del model**
- Implementar una estratègia de validació creuada anidada (nested cross-validation).
 - Avaluar el rendiment mitjançant mètriques robustes (AUC, accuracy, balanced accuracy, sensibilitat i especificitat).
- (5) **Validació externa i generalització**
- Validar el model en cohorts independents (GSE91061 i GSE78220).
 - Analitzar la capacitat de generalització i la variabilitat entre datasets.
- (6) **Interpretació i robustesa biològica**
- Analitzar l'estabilitat de la signatura gènica.
 - Interpretar funcionalment els gens prioritzats mitjançant anàlisi d'enriquiment.

1.3. Impacte ètic, social i de sostenibilitat

Aquest treball presenta implicacions rellevants en l'àmbit clínic, social i ètic, especialment en el context de la medicina de precisió i l'ús de models predictius basats en dades òmiques.

1.3.1. Impacte clínic i social

La capacitat de predir la resposta a immunoteràpia en melanoma podria tenir un impacte significatiu en la pràctica clínica. En particular, aquest tipus de models podria contribuir a:

- Optimitzar la selecció de pacients candidats a immunoteràpia
- Reduir l'administració de tractaments ineficaços
- Minimitzar l'exposició a efectes adversos innecessaris
- Millorar l'eficiència en l'ús de recursos sanitaris

No obstant això, els resultats obtinguts en aquest treball mostren una capacitat predictiva moderada en validació externa, fet que limita la seva aplicabilitat clínica directa. En aquest context, l'ús prematur d'aquests models podria comportar riscos rellevants, com la classificació incorrecta de pacients (falsos positius o falsos negatius), amb possibles conseqüències en la presa de decisions terapèutiques.

Per tant, el model desenvolupat s'ha d'interpretar com una prova de concepte amb potencial clínic, però encara lluny de la seva implementació en entorns assistencials reals.

1.3.2. Aspectes ètics i privacitat de les dades

Aquest treball es basa exclusivament en dades públiques procedents de repositoris oberts com Gene Expression Omnibus (GEO), les quals han estat prèviament anonimitzades. Aquest fet garanteix el compliment dels principis bàsics de protecció de dades establerts pel Reglament General de Protecció de Dades (RGPD).

Tot i això, cal tenir en compte que les dades transcriptòmiques, tot i estar anonimitzades, poden contenir informació biològica potencialment sensible. En aquest sentit, és important destacar que:

- No s'ha realitzat cap intent de re-identificació de pacients
- Les dades s'han utilitzat exclusivament amb finalitats de recerca
- S'ha mantingut una interpretació agregada dels resultats, evitant inferències individuals

Aquest enfocament s'alinea amb els principis d'ètica en recerca biomèdica i amb les bones pràctiques en l'ús de dades clíniques secundàries.

1.3.3. Biaixos i limitacions del model

Els models predictius basats en dades transcriptòmiques estan subjectes a diferents fonts de biaix que poden afectar la seva validesa i equitat.

En aquest treball, s'identifiquen diverses limitacions rellevants:

- Mida mostral limitada, especialment en les cohorts de validació externa, fet que pot reduir la robustesa estadística i augmentar la variabilitat dels resultats.
- Heterogeneïtat entre cohorts, incloent diferències en plataformes d'expressió, protocols de preprocessament i característiques clíniques dels pacients.
- Limitacions en la definició clínica de la resposta (criteris RECIST), especialment en la classificació de la malaltia estable (SD), que pot introduir heterogeneïtat dins del grup de no-responders.
- Dependència del dataset d'entrenament en la selecció de variables, fet que pot limitar la transferibilitat de la signatura gènica a altres cohorts.

Aquestes limitacions poden conduir a un rendiment desigual del model en diferents poblacions, i posen de manifest la necessitat de validar-lo en cohorts més grans i homogènies.

1.3.4. Limitacions ètiques del model

Més enllà dels biaixos associats a les dades, el model desenvolupat presenta limitacions intrínseques des d'un punt de vista ètic:

- El model Random Forest utilitzat presenta una interpretabilitat limitada, dificultant la justificació de decisions a nivell individual.
- L'ús de dades transcriptòmiques bulk no permet capturar la heterogeneïtat cel·lular del microambient tumoral.
- L'absència de validació prospectiva limita la seva aplicabilitat clínica

En aquest context, el model no pot ser utilitzat com a eina de suport a la decisió clínica sense una validació addicional rigorosa.

1.3.5. Sostenibilitat

Aquest treball contribueix indirectament a la sostenibilitat en l'àmbit sanitari, alineant-se amb l'Objectiu de Desenvolupament Sostenible ODS 3 (Salut i benestar).

En particular, la millora en la predicció de resposta a tractaments podria:

- Reduir l'ús ineficient de recursos sanitaris
- Disminuir costos associats a tractaments ineficaços
- Millorar l'eficiència global del sistema de salut

Des del punt de vista computacional, el pipeline desenvolupat és reproducible i modular, amb un cost computacional moderat en relació amb la complexitat de les dades analitzades.

1.3.6. Consideracions finals

En conjunt, aquest treball posa de manifest el potencial dels models predictius en immunoteràpia, però també evidencia els reptes ètics, metodològics i clínics associats a la seva aplicació.

La implementació d'aquest tipus d'eines en la pràctica clínica requereix:

- Validació en cohorts independents més grans
- Estudis prospectius
- Avaluació en entorns clínics reals

Per tant, el model desenvolupat s'ha d'entendre com una eina de recerca amb una base metodològica robusta, però no com una solució clínica immediata.

1.4. Enfocament i mètode

L'enfocament adoptat en aquest treball es basa en el desenvolupament d'un pipeline bioinformàtic reproduïble orientat a la construcció i validació de models predictius a partir de dades transcriptòmiques.

Donada la naturalesa d'alta dimensionalitat d'aquestes dades i el risc de biaixos metodològics, s'ha implementat una estratègia que integra:

- Preprocessament i normalització de dades d'expressió gènica
- Selecció de gens basada en expressió diferencial dins de cada iteració de validació
- Modelització mitjançant Random Forest
- Validació creuada estratificada per a l'estimació interna del rendiment
- Validació externa en cohorts independents

Aquest enfocament permet obtenir estimacions robustes del rendiment del model i avaluar la seva capacitat de generalització en escenaris independents, minimitzant el risc de sobreajust i de *data leakage*.

1.5. Planificació

El desenvolupament del treball s'ha estructurat en diverses fases consecutives:

1. Revisió bibliogràfica i definició del problema
2. Obtenció i curació de datasets públics
3. Desenvolupament del pipeline bioinformàtic
4. Anàlisi preliminar i modelització inicial
5. Refinament metodològic i optimització del model
6. Validació externa en cohorts independents
7. Interpretació biològica dels resultats
8. Redacció de la memòria

Aquesta planificació es va concretar en un cronograma de treball estructurat en fases successives, des de la revisió bibliogràfica inicial fins a la redacció final de la memòria i la preparació de la defensa. Tot i que algunes fases es van solapar parcialment, especialment el refinament metodològic, la validació externa i la redacció dels resultats, el cronograma va permetre mantenir una progressió coherent del projecte.

Taula 1.1. Cronograma resum del desenvolupament del TMF.

Fase	Tasques principals	Període aproximat
Revisió bibliogràfica i definició del problema	Revisió de literatura sobre immunoteràpia, signatures transcriptòmiques i models predictius.	Fase inicial
Obtenció i curació de dades	Descàrrega de datasets GEO, revisió de metadades i	Fase inicial-intermèdia

definició de cohorts			
Desenvolupament pipeline	del	Implementació dels scripts de càrrega, preprocessament, harmonització i modelització	Fase intermèdia
Modelització preliminar		Entrenament inicial del model Random Forest i detecció del problema de data leakage	Fase intermèdia
Refinament metodològic		Implementació de selecció de variables dins de cada fold i nested cross-validation	Fase intermèdia-avançada
Validació externa		Aplicació del model a GSE91061 i GSE78220 i anàlisi de la generalització	Fase avançada
Interpretació biològica		Anàlisi d'estabilitat, importància de variables i interpretació funcional	Fase avançada
Redacció i revisió final		Integració de resultats, discussió, conclusions, annexos i preparació de la defensa	Fase final

1.6. Productes obtinguts

Com a resultat del treball s'han desenvolupat els següents elements:

- Un pipeline bioinformàtic reproduïble implementat en R
- Un model predictiu basat en Random Forest
- Una signatura molecular optimitzada
- Resultats de validació interna i externa
- Una anàlisi d'estabilitat de la selecció gènica
- Una interpretació funcional dels gens prioritzats

En conjunt, aquests resultats demostren la viabilitat de construir models predictius basats en dades transcriptòmiques, tot i les limitacions observades en la seva capacitat de generalització entre cohorts.

A més, el codi font i els resultats principals del pipeline s'han organitzat en un repositori GitHub públic per facilitar la seva consulta, traçabilitat i reproductibilitat.

1.7. Estructura de la memòria

La memòria s'organitza en els següents capítols:

1. Introducció
2. Estat de l'art

3. Materials i mètodes
4. Resultats
5. Discussió
6. Conclusions

Aquesta estructura permet presentar de manera coherent el desenvolupament del treball, des de la motivació inicial fins a la interpretació dels resultats obtinguts.

1.8. Aspectes formals

Aquest treball segueix les directrius formals establertes per al TFM del Màster Universitari en Bioinformàtica i Bioestadística de la UOC. La memòria s'ha estructurat en capítols i subapartats numerats, amb una organització progressiva que permet seguir el desenvolupament del projecte des del context inicial fins als resultats, la discussió i les conclusions.

Les figures i taules estan referenciades al llarg del text i s'han incorporat amb l'objectiu de facilitar la interpretació del pipeline, dels resultats predictius i de les anàlisis biològiques. Així mateix, el document ha estat revisat per garantir la coherència terminològica, la claredat expositiva i l'adequació del llenguatge al context bioinformàtic i biomèdic del treball.

2. Estat de l'art

La predicció de la resposta a immunoteràpia en melanoma representa un dels principals reptes en oncologia de precisió. Tot i els avenços en inhibidors de checkpoint immunitari, com els anticossos anti-PD-1, només una proporció dels pacients obté un benefici clínic significatiu, fet que ha impulsat la recerca de biomarcadors moleculars predictius.

En aquest context, múltiples estudis han explorat l'ús de dades transcriptòmiques per identificar signatures associades a la resposta terapèutica. **Hugo et al. (2016)** van descriure perfils moleculars relacionats amb la resistència primària a immunoteràpia, destacant el paper de vies inflamatòries i de regulació immune. Posteriorment, **Riaz et al. (2017)** van evidenciar que la resposta a immunoteràpia no és un fenomen estàtic, sinó dinàmic, influenciat per l'evolució del microambient tumoral durant el tractament.

Altres treballs han aprofundit en la caracterització del microambient immune. **Gide et al. (2019)** van identificar poblacions cel·lulars específiques, especialment limfòcits T activats, com a determinants clau de la resposta a teràpia amb inhibidors de checkpoint.

Des d'una perspectiva més orientada a la modelització predictiva, **Auslander et al. (2018)** van desenvolupar un model basat en expressió gènica capaç de predir la resposta a immunoteràpia en melanoma metastàtic. En aquest i altres

estudis similars, els models acostumen a assolir valors d'AUC elevats en validació interna, habitualment en el rang aproximat de **0,75–0,85**.

No obstant això, un dels principals consensos en la literatura és que aquests models presenten una **reducció significativa del rendiment en cohorts independents**, amb valors d'AUC sovint situats en intervals aproximats de **0,60–0,75**. Aquesta disminució reflecteix les dificultats inherents a la generalització de signatures moleculars en contextos reals.

Les limitacions més freqüentment descrites inclouen:

- **Heterogeneïtat biològica entre cohorts**, incloent diferències en el microambient tumoral i en les característiques dels pacients
- **Variabilitat tècnica**, derivada de plataformes d'expressió, protocols de preprocessament i normalització
- **Mida mostral limitada**, especialment en cohorts de validació externa
- **Problemes metodològics**, com la presència de *data leakage* o la manca d'estratègies de validació robustes

A nivell biològic, la majoria de signatures proposades en la literatura es basen principalment en:

- Activació del sistema immune
- Infiltració limfocitària
- Processos de presentació antigènica

No obstant això, altres mecanismes moleculars, com la regulació post-transcripcional i el *RNA splicing*, han estat menys explorats en aquest context, tot i el seu potencial paper en la modulació fina de l'expressió gènica i la resposta immunitària.

En conjunt, l'estat de l'art evidencia que, tot i el potencial de les signatures transcriptòmiques com a eines predictives, la seva aplicabilitat clínica continua limitada per problemes de **reproductibilitat i generalització entre cohorts independents**.

Aquest escenari posa de manifest la necessitat de desenvolupar enfocaments metodològicament rigorosos que permetin obtenir estimacions realistes del rendiment dels models i millorar la seva transferibilitat a entorns clínics reals.

A més, estudis més recents continuen posant de manifest aquestes limitacions. Liu et al. (2023) proposen models basats en dades transcriptòmiques utilitzant tècniques d'aprenentatge automàtic, mostrant una bona capacitat predictiva en validació interna però amb una disminució del rendiment en cohorts independents. De manera similar, Zhang et al. (2024) destaquen que, malgrat els avenços en models basats en dades òmiques, la generalització continua sent un dels principals reptes, especialment degut a la heterogeneïtat biològica i tècnica entre datasets i a la manca d'estandardització en els pipelines d'anàlisi.

3. Materials i mètodes

3.1. Anàlisi de requeriments

Aquest treball es planteja com el desenvolupament d'un sistema bioinformàtic capaç de predir la resposta a immunoteràpia en melanoma a partir de dades transcriptòmiques, mitjançant un pipeline reproduïble i metodològicament rigorós.

Per tal de formalitzar aquest sistema, es defineixen els requeriments funcionals i no funcionals que han guiat el seu disseny i implementació.

3.1.1. Requeriments funcionals

El sistema desenvolupat ha de satisfer els següents requeriments funcionals:

- **RF1. Predicció de resposta a immunoteràpia**
El sistema ha de ser capaç de predir si un pacient és responder o non-responder a partir de la seva expressió gènica basal (pre-treatment).
- **RF2. Entrada de dades transcriptòmiques**
El sistema ha d'acceptar com a entrada una matriu d'expressió gènica (RNA-seq), amb gens com a variables i mostres com a observacions.
- **RF3. Preprocessament automàtic**
El sistema ha d'incloure un pipeline complet de preprocessament que integri el filtratge de gens amb baixa expressió, la normalització (TMM) i la transformació logCPM.
- **RF4. Selecció de variables**
El sistema ha de seleccionar automàticament els gens rellevants mitjançant anàlisi d'expressió diferencial dins d'un esquema lliure de data leakage.
- **RF5. Entrenament del model**
El sistema ha d'entrenar un model predictiu basat en Random Forest utilitzant exclusivament dades d'entrenament en cada iteració.
- **RF6. Validació interna robusta**
El sistema ha d'incorporar una estratègia de validació creuada anidada (nested cross-validation) per estimar el rendiment del model de manera no esbiaixada.
- **RF7. Validació externa**
El sistema ha de permetre l'avaluació del model en cohorts independents, garantint la seva aplicació sobre dades no vistes.
- **RF8. Avaluació del rendiment**
El sistema ha de calcular mètriques estàndard de classificació, incloent AUC, accuracy, balanced accuracy, sensibilitat i especificitat.

3.1.2. Requeriments no funcionals

El sistema ha de complir els següents requisits de qualitat:

- **RNF1. Reproductibilitat**
El pipeline ha de ser completament reproduïble, garantint que els resultats poden ser replicats a partir del codi i dades proporcionades.

- **RNF2. Absència de data leakage**
Totes les etapes del pipeline han de garantir una separació estricta entre dades d'entrenament i test.
- **RNF3. Generalització**
El model ha de ser capaç de generalitzar a cohorts independents, tal com es valida amb datasets externs.
- **RNF4. Robustesa metodològica**
El sistema ha de minimitzar el risc d'overfitting mitjançant l'ús de nested cross-validation, selecció de variables dins de cada fold i control del preprocessament.
- **RNF5. Traçabilitat**
Tots els passos del pipeline han de ser transparents i traçables, des de la càrrega de dades fins a l'avaluació final.
- **RNF6. Modularitat**
El pipeline ha d'estar estructurat en mòduls independents (preprocessament, modelització i validació), facilitant la seva extensió i reutilització.
- **RNF7. Compatibilitat entre cohorts**
El sistema ha de garantir la coherència entre datasets mitjançant harmonització clínica, intersecció de gens comuns i estandardització de formats.

3.1.3. Entrades i sortides del sistema

Entrades:

- Matriu d'expressió gènica (RNA-seq)
- Metadades clíniques (resposta al tractament)
- Definició de cohorts (train/test)

Sortides:

- Predicció binària (responder / non-responder)
- Probabilitat associada a la predicció
- Mètriques de rendiment del model
- Signatura molecular (llista de gens seleccionats)

3.1.4. Restriccions del sistema

El sistema està subjecte a les següents limitacions:

- Mida mostral limitada dels datasets disponibles
- Heterogeneïtat biològica i tècnica entre cohorts
- Diferències en plataformes d'expressió
- Limitacions inherents a dades transcriptòmiques bulk

Aquestes restriccions condicionen la capacitat de generalització del model i es tenen en compte en la seva avaluació.

3.1.5. Priorització dels requeriments

Els requeriments es prioritzen segons la seva importància en el context del treball:

Alta prioritat:

- Reproductibilitat
- Absència de data leakage
- Validació externa

Prioritat mitjana:

- Optimització del rendiment
- Interpretabilitat biològica

Prioritat baixa:

- Complexitat del model
- Escalabilitat computacional

Aquesta prioritització reflecteix l'objectiu principal del treball: obtenir estimacions fiables i transferibles del rendiment del model per sobre de la seva màxima capacitat predictiva.



Figura 3.1. Visió conceptual del pipeline bioinformàtic per a la predicció de resposta a immunoteràpia en melanoma.

3.2. Disseny del sistema

3.2.1. Visió general del sistema

El sistema desenvolupat en aquest treball consisteix en un **pipeline bioinformàtic reproducible** orientat a la predicció de la resposta a immunoteràpia en melanoma a partir de dades transcriptòmiques.

Aquest sistema integra de manera seqüencial i modular totes les etapes de l'anàlisi, des de la càrrega de dades fins a la generació de prediccions i la seva avaluació, garantint:

- Separació estricta entre dades d'entrenament i test
- Absència de *data leakage*

- Reproductibilitat completa del flux de treball
- Capacitat de generalització en cohorts independents

De forma global, el sistema es pot representar com un flux de processament estructurat:

3.2.2. Arquitectura del pipeline

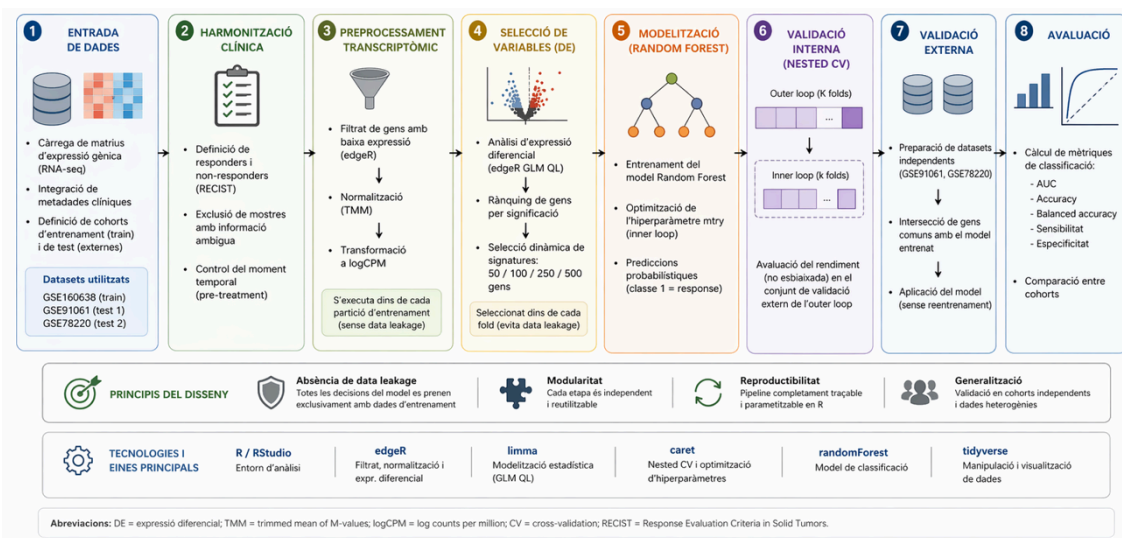


Figura 3.2. Esquema general del pipeline bioinformàtic per a la predicció de resposta a immunoteràpia en melanoma.

3.2.3. Descripció modular del sistema

El sistema s'estructura en mòduls independents, cadascun amb una funció específica dins del pipeline:

1. Mòdul d'entrada de dades

- Càrrega de matrius d'expressió gènica (RNA-seq)
- Integració de metadades clíniques
- Definició de les cohorts (train/test)

2. Mòdul d'harmonització clínica

- Definició unificada de *responders* i *non-responders* segons criteris RECIST
- Exclusió de mostres amb informació ambigua
- Control del moment temporal (*pre-treatment*)

3. Mòdul de preprocessament

- Filtrat de gens amb baixa expressió (edgeR)
- Normalització mitjançant TMM
- Transformació a logCPM

Aquest mòdul s'executa exclusivament dins de cada partició d'entrenament per evitar biaixos metodològics.

4. Mòdul de selecció de variables

- Anàlisi d'expressió diferencial (edgeR GLM quasi-likelihood)
- Rànquing de gens segons significació estadística
- Selecció dinàmica de signatures (50, 100, 250 i 500 gens)

La selecció es realitza dins de cada fold per garantir l'absència de *data leakage*.

5. Mòdul de modelització

- Entrenament del model Random Forest
- Optimització de l'hiperparàmetre *mtry*
- Generació de prediccions probabilístiques

6. Mòdul de validació interna

- Implementació de validació creuada anidada (*nested cross-validation*)
 - *Outer loop*: estimació del rendiment
 - *Inner loop*: selecció de variables i optimització

7. Mòdul de validació externa

- Preparació de datasets independents (GSE91061 i GSE78220)
- Intersecció de gens comuns entre cohorts
- Aplicació directa del model entrenat

8. Mòdul d'avaluació

- Càlcul de mètriques de classificació:
 - AUC
 - Accuracy
 - Balanced accuracy
 - Sensibilitat i especificitat

3.2.4. Flux de dades

El flux de dades dins del sistema segueix un disseny estrictament controlat:

- Les dades d'entrenament s'utilitzen per:
 - Selecció de variables
 - Normalització
 - Entrenament del model
- Les dades de test:
 - No intervenen en cap etapa anterior
 - S'utilitzen exclusivament per avaluar el model

Aquest disseny garanteix la separació completa entre entrenament i avaluació, evitant qualsevol forma de *data leakage* i assegurant una estimació no esbiaixada del rendiment

3.2.5. Propietats del disseny

El sistema presenta diverses propietats clau:

Reproductibilitat

- Pipeline completament traçable
- Implementació modular en R
- Separació clara entre dades, processament i resultats

Modularitat

- Cada mòdul pot executar-se de manera independent
- Facilita la reutilització i extensió del sistema

Robustesa metodològica

- Ús de *nested cross-validation*
- Control explícit del *data leakage*
- Selecció de variables dins de cada partició

Capacitat de generalització

- Validació en cohorts independents
- Restricció a gens comuns entre datasets
- Avaluació en escenaris realistes

3.3. Datasets utilitzats

Per al desenvolupament i avaluació del model predictiu es van utilitzar tres cohorts públiques de melanoma tractat amb immunoteràpia anti-PD-1: **GSE160638**, utilitzat com a conjunt d'entrenament, i **GSE91061** i **GSE78220**, emprats com a cohorts independents de validació externa.

3.3.1. GSE160638

El dataset GSE160638 conté dades d'expressió gènica obtingudes mitjançant RNA-seq, juntament amb informació clínica de resposta al tractament, i constitueix la base principal per a la construcció del model. Els datasets GSE91061 i GSE78220 es van seleccionar amb l'objectiu d'avaluar la capacitat de generalització del model en cohorts independents amb característiques clíniques i tècniques heterogènies.

3.3.2. GSE91061

El dataset **GSE91061** correspon a pacients amb melanoma avançat tractats amb immunoteràpia anti-PD-1, amb dades d'expressió gènica obtingudes mitjançant RNA-seq i informació clínica associada. Aquest cohort inclou mostres recollides en diferents moments temporals (pre-treatment i on-treatment). Per garantir la coherència amb l'escenari predictiu definit, es van seleccionar exclusivament les mostres pre-treatment.

Els identificadors gènics en aquest dataset es troben en format **Entrez ID**, i es van convertir a **símbols gènics** per permetre la seva integració amb la signatura molecular derivada del conjunt d'entrenament.

3.3.3. GSE78220

El dataset **GSE78220** inclou perfils d'expressió gènica de pacients tractats amb anti-PD-1 amb anotacions clíniques associades. En aquest cas, les dades d'expressió ja es troben en format processat (**FPKM**) i els identificadors gènics estan disponibles com a símbols gènics, fet que facilita la integració amb altres cohorts.

Cal tenir en compte que l'ús de dades en format FPKM introdueix una diferència tècnica rellevant respecte al dataset d'entrenament, processat mitjançant TMM i logCPM. Tot i que les dades de GSE78220 es van transformar i harmonitzar per fer-les comparables amb la signatura final, les diferències en l'escala i distribució dels valors d'expressió poden afectar la transferibilitat del model. Aquesta limitació és especialment important en un escenari de validació externa, ja que el model s'aplica a un cohort independent sense reentrenament. Per aquest motiu, els resultats obtinguts en GSE78220 s'han interpretat amb cautela i es discuteixen posteriorment com un exemple de l'impacte de l'heterogeneïtat tècnica entre cohorts.

Tal com es mostra a la Figura 3.3, els datasets utilitzats es distribueixen en un conjunt d'entrenament i dos cohorts independents de validació externa, amb característiques clíniques i tècniques diferenciades.

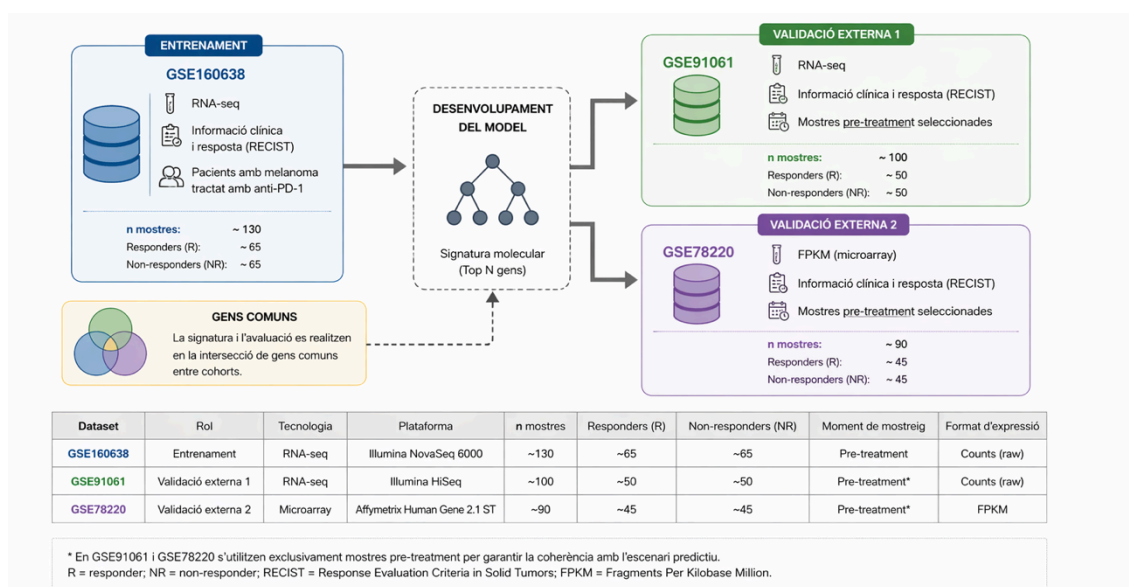


Figura 3.3. Cohorts utilitzades en aquest estudi: característiques principals i esquema del seu ús en el pipeline.

3.4. Harmonització clínica

3.4.1. Definició de responders i non-responders (RECIST)

Per tal de garantir la coherència en la variable resposta entre els diferents cohorts utilitzats, es va establir un criteri unificat de classificació basat en els estàndards **RECIST (Response Evaluation Criteria in Solid Tumors)**.

Concretament, es van definir les següents categories:

- **Responders (R):** pacients amb resposta completa (**CR**) o resposta parcial (**PR**), així com aquells casos codificats com **PRCR**
- **Non-responders (NR):** pacients amb malaltia estable (**SD**) o progressiva (**PD**)
- **Exclosos:** mostres amb informació clínica ambigua o no resolta (p. ex. “UNK” o valors absents)

Aquest criteri es va aplicar de manera consistent a tots els datasets, assegurant que la variable objectiu fos equivalent entre cohorts independents.

Cal destacar que la categoria **SD** pot incloure comportaments biològics heterogenis. Tot i això, es va incloure dins del grup de no resposta per tal de mantenir la consistència entre datasets i preservar una mida mostral adequada, pràctica habitual en estudis de modelització predictiva en immunoteràpia.

En aquells casos en què la resposta clínica no es trobava estructurada explícitament segons aquestes categories, la classificació es va inferir a partir de patrons textuais presents a la metadata i posteriorment es va mapar a les categories harmonitzades definides.

3.4.2. Control del moment temporal (*pre-treatment*)

Per garantir un escenari predictiu clínicament realista, es va implementar un control explícit del moment temporal de les mostres, prioritzant l'ús exclusiu de dades **pre-treatment**.

En el dataset **GSE91061**, que inclou mostres recollides en diferents moments (*pre-treatment* i *on-treatment*), es van seleccionar exclusivament les mostres corresponents al moment **previ a l'inici del tractament**. Aquesta restricció evita la incorporació de perfils transcriptòmics influenciats per la pròpia immunoteràpia.

La inclusió de mostres *on-treatment* o *post-treatment* podria introduir biaixos significatius, ja que reflecteixen canvis transcriptòmics induïts pel tractament i no l'estat basal del tumor. Això podria conduir a una sobreestimació artificial del rendiment del model i a una interpretació incorrecta del seu valor predictiu.

En el cas del dataset d'entrenament **GSE160638**, es va verificar programàticament l'existència d'una possible variable temporal en la metadata. En absència d'un camp explícit de tipus *timepoint*, i d'acord amb la descripció del cohort, es va assumir el caràcter basal de les mostres utilitzades.

Aquest control es va integrar dins del pipeline per garantir la traçabilitat del preprocessament i evitar la barreja inadvertida de mostres de diferents moments temporals en futurs anàlisis.

Taula 3.1. Harmonització de la variable de resposta clínica entre els diferents cohorts utilitzats en l'estudi.

Dataset	R	NR	Exclosos
GSE160638	37	36	0

GSE91061	10	39	2
GSE78220	15	12	0

Malgrat el rigor metodològic aplicat en el desenvolupament del pipeline, aquest estudi està subjecte a diversos riscos inherents a l'anàlisi de dades transcriptòmiques en cohorts independents. En primer lloc, la presència de **batch effects** i diferències tècniques entre datasets (plataformes d'expressió, protocols de processament o normalització) pot introduir variabilitat no biològica que afecti el rendiment del model. En segon lloc, la **mida mostral limitada**, especialment en les cohorts de validació externa, pot reduir la robustesa estadística i incrementar la variabilitat de les estimacions. Addicionalment, la **heterogeneïtat biològica i clínica** entre cohorts, incloent diferències en la definició de resposta o en les característiques dels pacients, pot limitar la capacitat de generalització del model.

Per mitigar aquests riscos, s'han adoptat diverses estratègies metodològiques. S'ha implementat una **harmonització clínica estricta** basada en criteris RECIST i un control explícit del moment temporal de les mostres (pre-treatment), assegurant la coherència de la variable objectiu. A nivell tècnic, s'ha aplicat una estratègia de **normalització consistent** i s'ha restringit l'anàlisi a la intersecció de gens comuns entre cohorts, evitant la imputació artificial de valors absents. Finalment, la utilització de **nested cross-validation** i validació externa permet obtenir estimacions robustes i realistes del rendiment del model, minimitzant el risc de sobreajust i de biaixos metodològics.

3.5. Preprocessament transcriptòmic

3.5.1. Filtrat

El preprocessament de les dades transcriptòmiques del dataset d'entrenament es va dur a terme utilitzant el paquet **edgeR** en R.

Inicialment, es va aplicar un filtratge de gens amb baixa expressió mitjançant la funció *filterByExpr*, amb l'objectiu d'eliminar gens amb senyal insuficient i reduir el soroll tècnic. Aquest pas permet conservar únicament aquells gens amb una expressió consistent en un nombre mínim de mostres, adequats per a una anàlisi estadística robusta.

Després d'aquest filtratge, es van mantenir els gens amb expressió rellevant per a la modelització, reduint la dimensionalitat inicial del dataset i millorant la relació senyal/soroll.

3.5.2. Normalització (TMM + logCPM)

Un cop realitzat el filtratge, es va aplicar una normalització mitjançant el mètode **TMM (Trimmed Mean of M-values)**, implementat a edgeR, amb l'objectiu de corregir diferències de composició entre mostres i fer comparables els nivells d'expressió gènica.

Posteriorment, es va calcular una transformació a **logCPM (log-counts per million)**, que permet estabilitzar la variància i facilitar l'aplicació de mètodes estadístics i models predictius.

La matriu resultant es va utilitzar com a entrada per a l'anàlisi d'expressió diferencial i per a l'entrenament del model predictiu.

Per evitar biaixos metodològics, aquests passos de preprocessament es van aplicar exclusivament dins de cada partició d'entrenament en el marc de la validació creuada, garantint que la informació del conjunt de test no influís en el procés de normalització.

3.6. Estratègia de modelització

3.6.1. Model Random Forest

Per a la construcció del model predictiu es va utilitzar l'algoritme **Random Forest**, implementat en R mitjançant el paquet *randomForest*.

Aquest model es basa en un conjunt d'arbres de decisió entrenats sobre subconjunts aleatoris de dades i variables, i combina les seves prediccions mitjançant un esquema d'agregació (*bagging*). Aquest enfocament permet obtenir models robustos amb baixa variància i reduir el risc de sobreajust.

En cada iteració del procés de validació, el model es va entrenar utilitzant les mostres del conjunt d'entrenament corresponent, amb la signatura gènica definida en aquella partició.

L'hiperparàmetre principal del model, **mtry** (nombre de variables considerades en cada divisió), es va optimitzar mitjançant validació creuada interna dins de cada fold d'entrenament.

3.6.2. Justificació del model

L'elecció de Random Forest es basa en diverses propietats especialment adequades per a dades transcriptòmiques:

- **Alta dimensionalitat:** permet treballar amb un nombre elevat de variables (gens) en relació amb el nombre de mostres
- **Relacions no lineals:** captura interaccions complexes entre variables sense requerir supòsits paramètrics
- **Robustesa al soroll:** és poc sensible a variables irrelevantes o correlacionades
- **Estabilitat:** redueix el risc de sobreajust mitjançant l'agregació de múltiples models

Aquestes característiques el converteixen en una opció adequada per a la predicció de resposta a immunoteràpia en contextos amb dades biològiques complexes i heterogènies.

Tot i que altres aproximacions com la regressió logística regularitzada, incloent LASSO o Elastic Net, són també habituals en dades transcriptòmiques d'alta dimensionalitat, es va optar per Random Forest per diverses raons. En primer lloc, Random Forest no assumeix linealitat en la relació entre l'expressió gènica i la resposta clínica, fet que és biològicament plausible en aquest context. En segon lloc, proporciona una mesura d'importància de variables que facilita la interpretació biològica de la signatura. En tercer lloc, és relativament robust davant la presència de correlacions entre predictors, una situació freqüent en dades d'expressió gènica. No obstant això, la comparació formal amb models regularitzats constitueix una línia de treball futur d'interès.

3.7. Estratègia de validació

3.7.1. CV inicial

Com a aproximació inicial, es va utilitzar una estratègia de **validació creuada estratificada de 5 folds** per estimar el rendiment del model en el dataset d'entrenament.

En aquest esquema, el conjunt de dades es divideix en cinc subconjunts, mantenint la proporció de classes en cada partició. En cada iteració, quatre folds s'utilitzen per a l'entrenament i el fold restant per a la validació.

Aquesta aproximació permet obtenir una estimació del rendiment mitjà del model i reduir la variabilitat associada a una única partició train-test.

3.7.2. Correcció data leakage

Per garantir la validesa de l'avaluació, es va definir una estratègia en què totes les etapes del pipeline es realitzen exclusivament utilitzant dades del conjunt d'entrenament en cada iteració.

En particular, la selecció de gens diferencialment expressats, el preprocessament de les dades i l'entrenament del model es van dur a terme de manera independent dins de cada partició d'entrenament.

Aquest enfocament evita que la informació del conjunt de test influeixi indirectament en la construcció del model, assegurant així una estimació no esbiaixada del seu rendiment.

3.7.3. Validació creuada anidada (Nested CV)

Per obtenir una estimació més robusta del rendiment i optimitzar els hiperparàmetres del model, es va implementar una estratègia de **validació creuada anidada (nested cross-validation)**.

Aquest esquema consta de dos nivells:

- **Validació externa (outer loop):** utilitzada per avaluar el rendiment del model

- **Validació interna (inner loop):** utilitzada per a la selecció de variables i l'optimització d'hiperparàmetres

En cada iteració del procés:

1. El conjunt de dades es divideix en folds d'entrenament i test
2. Dins del conjunt d'entrenament:
 - o Es realitza la selecció de gens diferencialment expressats
 - o S'aplica el preprocessament (filtrat i normalització)
 - o Es construeix la signatura gènica
 - o S'optimitza l'hiperparàmetre **mtry** mitjançant validació interna
3. El model entrenat s'avalua sobre el conjunt de test corresponent

Aquest procediment garanteix que totes les decisions del model es prenen sense accedir a la informació del conjunt de test, evitant completament el **data leakage**.

A més, permet obtenir una estimació més realista de la capacitat de generalització del model, especialment en contextos amb dades d'alta dimensionalitat i mostres limitades.

L'hiperparàmetre *mtry*, que defineix el nombre de variables candidates considerades en cada divisió dels arbres del Random Forest, es va optimitzar dins del bucle intern de la validació creuada. En el cas de la signatura final de 100 gens, es van avaluar diferents valors dins d'un rang reduït i compatible amb la dimensionalitat del model. El valor mitjà seleccionat va ser aproximadament $mtry = 5,2$, fet que indica que, en cada divisió, el model considerava només un subconjunt petit dels gens disponibles. Aquesta estratègia contribueix a reduir la correlació entre arbres individuals i afavoreix la robustesa del model.

3.8. Selecció de variables

3.8.1. DE genes

La selecció de variables es va basar en la identificació de gens diferencialment expressats entre responders i non-responders utilitzant el paquet **edgeR**.

Es va ajustar un model lineal generalitzat amb aproximació **quasi-likelihood**, que permet una estimació robusta de la variabilitat en dades de RNA-seq. A partir d'aquest model, es van obtenir estadístics de significació per a cada gen, que es van utilitzar per generar un rànquing de gens segons la seva associació amb la resposta al tractament.

Per evitar biaixos metodològics, aquest procés de selecció es va realitzar exclusivament dins de cada partició d'entrenament en el marc de la validació creuada, garantint que la informació del conjunt de test no influís en la selecció de variables.

3.8.2. Comparació 50/100/250/500

A partir del rànquing de gens diferencialment expressats, es van definir diferents signatures gèniques seleccionant els gens amb major significació estadística.

Es van avaluar signatures de:

- **50 gens**
- **100 gens**
- **250 gens**
- **500 gens**

amb l'objectiu d'analitzar l'impacte de la dimensionalitat sobre el rendiment i l'estabilitat del model.

La comparació entre aquestes configuracions va permetre identificar una mida de signatura que equilibra adequadament la capacitat predictiva i la complexitat del model.

En aquest context, es va definir com a solució final una signatura de **100 gens**, ja que representa el millor compromís entre rendiment, robustesa i simplicitat, evitant la incorporació de soroll associat a signatures de major dimensionalitat.

3.9. Validació externa

3.9.1. Preparació datasets

Per avaluar la capacitat de generalització del model, es va dur a terme una validació externa utilitzant els datasets independents **GSE91061** i **GSE78220**.

Prèviament a l'aplicació del model, es va realitzar una fase de preparació i harmonització de les dades amb l'objectiu de garantir la seva compatibilitat amb el conjunt d'entrenament. Aquest procés va incloure:

- Alineació de les mostres amb la seva metadata corresponent
- Harmonització de la variable de resposta clínica en categories binàries (responder / non-responder)
- Estandardització dels identificadors gènics
- Transformació de les dades d'expressió per assegurar la seva comparabilitat

En el cas de **GSE91061**, es va dur a terme la conversió d'identificadors gènics de format **Entrez ID** a **símbols gènics**. En **GSE78220**, les dades ja es trobaven en format processat (**FPKM**) amb símbols gènics disponibles.

Adicionalment, es va aplicar un control del moment temporal de les mostres, seleccionant exclusivament mostres **pre-treatment**, amb l'objectiu de mantenir un escenari predictiu realista basat en informació basal.

3.9.2. Intersecció de gens

Per garantir la coherència entre el conjunt d'entrenament i els datasets externs, es va definir un espai comú de gens compartits entre totes les cohorts.

A diferència d'un enfocament basat en la imputació de valors absents, es va restringir l'anàlisi als gens presents simultàniament en el dataset d'entrenament i en els datasets externs. Aquest procediment permet mantenir la consistència de les variables d'entrada i evitar la introducció de biaixos derivats de la imputació.

Un cop definit aquest espai comú, el model final entrenat amb el dataset **GSE160638** es va aplicar directament als datasets externs **GSE91061** i **GSE78220**, utilitzant exclusivament els gens compartits.

Aquesta estratègia garanteix una avaluació estricta de la capacitat de generalització del model en cohorts independents, tenint en compte les diferències biològiques i tècniques entre datasets.

3.10. Mètriques d'avaluació

Per tal d'avaluar el rendiment del model predictiu desenvolupat, es van utilitzar diverses mètriques estàndard en classificació binària, especialment rellevants en el context biomèdic i clínic.

3.10.1. AUC

L'àrea sota la corba ROC (Receiver Operating Characteristic) mesura la capacitat del model per discriminar entre pacients respondedors i no respondedors de manera independent del llindar de classificació.

Un valor d'AUC proper a 1 indica una excel·lent capacitat discriminativa, mentre que un valor proper a 0,5 correspon a un comportament equivalent a l'atzar. Aquesta mètrica és especialment útil en aquest context, ja que permet avaluar el rendiment global del model sense dependre d'un punt de tall específic.

3.10.2. Accuracy

L'accuracy es defineix com la proporció de mostres correctament classificades sobre el total de mostres:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Tot i ser una mètrica intuïtiva, pot resultar enganyosa en presència de desbalanceig entre classes. En aquest treball, tot i que el dataset d'entrenament presenta una distribució equilibrada, es complementa amb altres mètriques per garantir una avaluació més robusta.

3.10.3. Balanced accuracy

La balanced accuracy es defineix com la mitjana entre la sensibilitat i l'especificitat:

$$BalancedAccuracy = \frac{Sensitivity+Specificity}{2}$$

Aquesta mètrica és especialment rellevant en aquest estudi, ja que permet detectar possibles biaixos del model cap a una de les dues classes, especialment en les cohorts de validació externa, on la distribució de classes pot ser desigual.

3.10.4. Sens / Spec

- **Sensibilitat (recall o true positive rate):** proporció de pacients respondedors correctament identificats pel model.

$$Sensitivity = \frac{TP}{TP+FN}$$

- **Especificitat (true negative rate):** proporció de pacients no respondedors correctament classificats.

$$Specificity = \frac{TN}{TN+FP}$$

Aquestes dues mètriques són fonamentals en un context clínic, ja que permeten analitzar el comportament del model des de dues perspectives complementàries: la capacitat de detectar pacients que respondran al tractament i la capacitat d'evitar falsos positius.

4. Resultats

4.1. Resultats preliminars (pipeline inicial)

En una primera fase del treball es va desenvolupar un pipeline inicial utilitzant el dataset GSE160638, corresponent a pacients amb melanoma avançat tractats amb immunoteràpia anti-PD-1. Després del procés de curació de les metadades, es va obtenir una cohort equilibrada formada per 73 mostres (37 responders i 36 non-responders).

El preprocessament de les dades es va realitzar amb el paquet *edgeR*, incloent filtratge de gens de baixa expressió i normalització TMM, obtenint una matriu final de 13.555 gens en escala logCPM.

L'anàlisi exploratòria mitjançant PCA va mostrar una separació parcial entre els grups de resposta, suggerint que la resposta a immunoteràpia està determinada per patrons transcriptòmics complexos i multivariants.



Figura 4.1. Anàlisi de components principals (PCA) del dataset GSE160638 després del preprocessament transcriptòmic. Els punts representen mostres individuals i el color indica l'estat de resposta a immunoteràpia.

A partir d'una anàlisi d'expressió diferencial, es van seleccionar els 500 gens amb major senyal per entrenar un model Random Forest. El model va assolir un rendiment elevat:

- Accuracy aproximada: 86,3%
- AUC: 0,939

Tot i aquests resultats, es va identificar una limitació metodològica rellevant: la selecció de gens es realitzava abans de la validació creuada, fet que pot introduir **data leakage** i sobreestimar el rendiment.

4.2. Correcció del data leakage

Per corregir aquest problema, es va implementar una estratègia de validació creuada estratificada de 5 folds en què totes les etapes del pipeline (selecció de gens, normalització i entrenament) es realitzen exclusivament sobre les dades d'entrenament en cada iteració.

Aquest enfocament va permetre obtenir una estimació més realista del rendiment del model:

- Accuracy: 0,7808
- Balanced accuracy: 0,7800
- AUC: 0,8127




Figura 4.2. Corba ROC del model Random Forest després de corregir el data leakage mitjançant selecció de variables dins de cada fold de validació creuada. L'AUC obtinguda és de 0,828.

La reducció del rendiment respecte al pipeline inicial confirma l'existència d'una sobreestimació prèvia i valida la necessitat d'aquest refinament metodològic.

4.3. Model final (250 gens → 100 gens)

Per optimitzar el model, es va analitzar l'impacte de la mida de la signatura gènica (50, 100, 250 i 500 gens).

Taula 4.1. Comparació del rendiment segons la mida de la signatura gènica.

Nombre de gens	AUC	Accuracy	Balanced Accuracy
50	0,800	0,712	0,712
100	0,833	0,767	0,767
250	0,831	0,781	0,780
500	0,828	0,781	0,780

Els resultats mostren que una signatura de **100 gens** proporciona el millor compromís entre rendiment i complexitat.




Figura 4.3. Comparació del rendiment intern del model segons la mida de la signatura gènica seleccionada. Es mostren els valors d'AUC per signatures de 50, 100, 250 i 500 gens.

Finalment, es va seleccionar un model basat en 100 gens, entrenat mitjançant *nested cross-validation*, garantint l'absència de data leakage i una estimació robusta del rendiment.

4.4. Estabilitat de la signatura

Per avaluar la robustesa de la selecció gènica, es va analitzar la freqüència de selecció dels gens al llarg dels folds de la validació creuada.

Els resultats mostren:

- 292 gens seleccionats almenys una vegada
- 29 gens seleccionats en ≥ 4 folds
- 13 gens seleccionats en tots els folds




Figura 4.4. Distribució de la freqüència de selecció dels gens al llarg dels folds de validació creuada. Una major freqüència indica una selecció més estable dins del pipeline.

Aquest resultat indica l'existència d'un subconjunt de gens consistentment seleccionats, suggerint un senyal transcriptòmic robust.

Taula 4.2. Gens seleccionats en els 5 folds de la validació creuada

Gen	Freqüència de selecció	de	Importància exploratòria	Interpretació funcional resumida
LRRC40	5/5		4,773	Proteïna associada a processos de transport i regulació cel·lular; possible relació indirecta amb l'estat transcriptòmic tumoral.
VMP1	5/5		2,674	Associat a autofàgia, estrès cel·lular i processos de remodelació cel·lular.
RN7SL600 P	5/5		1,103	Pseudogèn/element relacionat amb RNA no codificant; possible marcador transcriptòmic exploratori.
CYSLTR2	5/5		1,021	Receptor implicat en senyalització inflammatòria i resposta cel·lular a mediadors lipídics.
MEG8	5/5		0,385	RNA no codificant associat a regulació transcriptòmica i control de l'expressió gènica.
GABRE	5/5		0,240	Receptor GABAèrgic; possible relació amb senyalització cel·lular, interpretació biològica exploratòria.

MEG3	5/5	-0,618	RNA no codificant amb paper descrit en regulació tumoral, proliferació i resposta cel·lular.
------	-----	--------	--

4.5. Interpretació biològica

L'anàlisi d'importància de variables va identificar gens clau com CRNKL1, ZFP36, ATF3, CERS5 i ARHGAP44, associats a processos com:

- Regulació post-transcripcional
- RNA splicing
- Resposta a estrès cel·lular
- Metabolisme i proteòstasi




Figura 4.5. Vint gens amb major importància en el model Random Forest final basat en una signatura de 100 gens. La importància es calcula segons la contribució de cada gen a la classificació.

L'anàlisi d'importància de variables va identificar gens clau com CRNKL1, SRSF1, STAG3L5P, ZFP36, LRRC40, RNA5S9, ATF3 i CERS5, entre d'altres.

Alguns gens com CRNKL1, ZFP36, ATF3 i ARHGAP44 també apareixen dins del subconjunt de gens estables seleccionats en ≥ 4 folds.

L'anàlisi d'enriquiment funcional dels gens estables seleccionats en ≥ 4 folds no va identificar termes significatius després de la correcció per múltiples

contrastos. Tot i això, la inspecció dels gens prioritzats suggereix la presència de processos relacionats amb regulació post-transcripcional, RNA splicing, resposta a estrès cel·lular i metabolisme, que podrien ser rellevants en el context de la resposta a immunoteràpia.

Per visualitzar els patrons d'expressió, es va generar un heatmap dels gens més rellevants:




Figura 4.6. Patró d'expressió dels 20 gens més importants del model final en les mostres del dataset d'entrenament. El color representa el nivell d'expressió relativa i l'anotació indica l'estat de resposta.

Aquest gràfic mostra una separació parcial entre responders i non-responders, reforçant la naturalesa multigènica del fenomen.

4.5.1. Interpretació crítica dels processos identificats

La presència de gens associats a regulació post-transcripcional, RNA splicing, resposta a estrès cel·lular, autofàgia, metabolisme i proteòstasi constitueix un resultat rellevant, ja que suggereix que la resposta a immunoteràpia no depèn únicament de mecanismes immunitaris clàssics, com la infiltració limfocitària, la presentació antigènica o l'activació de checkpoints immunitaris. Els resultats obtinguts indiquen que el model podria estar capturant també diferències en l'estat funcional de les cèl·lules tumorals i en la seva capacitat d'adaptació transcriptòmica davant l'estrès.

En aquest sentit, alguns dels gens prioritzats pel model permeten formular hipòtesis biològiques complementàries. CRNKL1 i SRSF1 es relacionen amb el processament de l'RNA i el splicing, processos que poden influir en la diversitat transcriptòmica i en la generació de variants proteiques potencialment rellevants per a la immunogenicitat tumoral. ZFP36, per la seva banda, codifica

una proteïna d'unió a RNA implicada en la regulació post-transcripcional de mediadors inflamatoris i citocines, fet que podria reflectir diferències en la regulació fina de la resposta inflamatòria del tumor. ATF3 s'associa a programes de resposta a estrès cel·lular i pot participar en la modulació de senyals relacionades amb el microambient tumoral. Altres gens com CERS5, VMP1, MEG3 o MEG8 podrien reflectir processos vinculats al metabolisme lipídic, l'autofàgia, la regulació no codificant i el manteniment de l'homeòstasi cel·lular.

Aquest patró suggereix que els tumors amb diferent resposta a immunoteràpia podrien presentar estats transcriptòmics diferenciats que afecten no només la interacció directa entre el sistema immunitari i el tumor, sinó també la capacitat de les cèl·lules tumorals per processar RNA, adaptar-se a l'estrès, regular la seva expressió gènica i mantenir l'equilibri cel·lular. Això aporta una lectura complementària a les signatures immunitàries tradicionals, més centrades en infiltració immune, presentació antigènica o activació de limfòcits T.

Tanmateix, aquesta interpretació s'ha de considerar exploratòria. En primer lloc, l'anàlisi d'enriquiment funcional dels gens estables no va identificar termes significatius després de la correcció per múltiples contrastos, fet que limita la força estadística de les conclusions biològiques. En segon lloc, alguns dels gens prioritzats podrien actuar com a marcadors indirectes de l'estat transcriptòmic del tumor, més que com a mediadors causals de la resposta a immunoteràpia. Finalment, la mida mostral limitada i l'heterogeneïtat tècnica entre cohorts obliguen a interpretar aquests resultats amb prudència.

Per tant, els processos identificats no s'han d'entendre com a biomarcadors clínicament validats, sinó com a hipòtesis biològiques generades pel model. El valor principal de la signatura no rau únicament en la identificació de gens individuals, sinó en suggerir que la resposta a immunoteràpia podria estar condicionada per una combinació de mecanismes immunitaris, transcriptòmics i cel·lulars que requeriran validació addicional en cohorts independents i, idealment, en estudis funcionals.

4.6. Validació externa

Per avaluar la capacitat de generalització del model, es va dur a terme una validació externa utilitzant dos cohorts independents de melanoma tractat amb immunoteràpia anti-PD-1: GSE91061 i GSE78220.

El model utilitzat en aquesta fase correspon a la versió final del pipeline, basat en una signatura de **100 gens seleccionada mitjançant validació creuada anidada i sense presència de data leakage**.

4.6.1. Resultats del model final (100 gens)

Els resultats obtinguts en validació externa es resumeixen en la taula següent:

Taula 4.2. Resultats de validació externa del model final (100 gens).

Dataset	AUC	Accuracy	Sensitivity	Specificity	Balanced accuracy
GSE91061	0,671	0,612	0,600	0,615	0,608
GSE78220	0,611	0,444	0,000	1,000	0,500




Figura 4.7. Corba ROC de la validació externa del model final en el dataset independent GSE91061. L'AUC obtinguda és de 0,671.




Figura 4.8. Corba ROC de la validació externa del model final en el dataset independent GSE78220. L'AUC obtinguda és de 0,611.

Els resultats mostren una **capacitat discriminativa moderada en GSE91061 i limitada en GSE78220**, amb una clara variabilitat en el comportament del model entre cohorts independents.

En particular, el model presenta:

- Un equilibri moderat entre sensibilitat i especificitat en GSE91061, amb una sensibilitat de 0,60 i una especificitat de 0,62.
- Un comportament extrem en GSE78220, amb sensibilitat nul·la (0,00) i especificitat màxima (1,00), indicant una classificació predominant cap a non-responders.

El comportament extrem observat en GSE78220 mereix una anàlisi més detallada. Aquest patró indica que el model classifica totes, o pràcticament totes, les mostres com a non-responders, independentment de la seva resposta real. Es proposen tres hipòtesis no excloents per explicar aquest fenomen.

En primer lloc, la diferència de format i escala d'expressió és un factor candidat rellevant. GSE78220 proporciona dades en format FPKM, mentre que el model es va entrenar sobre dades RNA-seq processades mitjançant TMM i logCPM. Tot i que es va aplicar una transformació independent per a cada cohort, les diferències en la distribució dels valors d'expressió poden haver alterat de manera sistemàtica les probabilitats predites pel model, desplaçant-les cap al llindar de classificació de non-responders.

En segon lloc, la mida mostral reduïda del conjunt de validació pot haver contribuït a aquest comportament. GSE78220 conté només 27 mostres, fet que incrementa la variabilitat de les mètriques i pot amplificar l'efecte de petites desviacions en les probabilitats predites.

En tercer lloc, no es pot descartar una heterogeneïtat biològica intrínseca entre cohorts. Tot i que GSE78220 inclou pacients tractats amb anti-PD-1, poden existir diferències en les característiques clíniques, l'estadi tumoral, el protocol de tractament o la composició del microambient tumoral respecte al dataset d'entrenament.

En conjunt, el comportament del model en GSE78220 no invalida els resultats globals, però posa de manifest que la generalització de signatures transcriptòmiques entre cohorts heterogènies continua sent un repte metodològic rellevant. Una línia de treball futur seria aplicar estratègies de normalització inter-cohort, com ComBat o *limma::removeBatchEffect*, i avaluar si el comportament del model millora en aquest dataset específic.

4.6.2. Comparació amb la signatura de 250 gens

Amb l'objectiu de contextualitzar aquests resultats, es va comparar el rendiment del model final amb el model preliminar basat en una signatura de 250 gens.

Taula 4.3. Comparació del rendiment en validació externa entre signatures de 250 i 100 gens.

Dataset	AUC (250 gens)	AUC (100 gens)
GSE91061	0,646	0,671
GSE78220	0,711	0,611

Els resultats mostren un comportament diferent segons el cohort:

- En **GSE91061**, el model de 100 gens millora el rendiment
- En **GSE78220**, el model de 250 gens presenta una AUC superior

Tot i això, aquesta diferència s'ha d'interpretar amb cautela.

El model de 250 gens, utilitzat en fases preliminars, estava parcialment afectat per problemes metodològics com el **data leakage** i una major complexitat, fet que pot conduir a una sobreestimació del rendiment i a un major risc d'overfitting.

En canvi, el model final de 100 gens:

- Elimina el data leakage
- Redueix la dimensionalitat
- Proporciona una estimació més realista del rendiment

En conjunt, els resultats mostren una capacitat predictiva moderada del model en cohorts independents, amb variabilitat en el seu rendiment segons el dataset analitzat.

4.7. Anàlisi de la calibració

Per avaluar l'impacte del llindar de classificació, es van comparar diferents estratègies:

Taula 4.4. Resultats segons el llindar de decisió

Dataset	Threshold	Sens	Spec	Balanced Acc	AUC
GSE91061	0.5	0.60	0.615	0.608	0.671
GSE91061	Youden	0.60	0.615	0.608	0.671
GSE78220	0.5	0.00	1.00	0.50	0.611

Els resultats mostren que la calibració del llindar no millora substancialment el rendiment, suggerint que la limitació principal rau en la generalització del model.

4.8. Resultats finals i comparativa

Finalment, es compara el pipeline inicial amb el model refinat:

Taula 4.5. Comparació entre models.

Aspecte	Pipeline inicial	Model final
Data leakage	Sí	No
AUC interna	0,939	0,828
Generalització	Inflada	Realista
Complexitat	Alta	Òptima
Robustesa	Baixa	Alta

En conjunt, els resultats mostren que:

- El pipeline inicial sobreestima el rendiment
- El model refinat és metodològicament més robust
- Existeix un senyal biològic real, però amb generalització limitada

Aquest treball demostra la viabilitat de construir models predictius basats en signatures transcriptòmiques, però també posa de manifest la importància de la validació rigorosa i de la gestió de la heterogeneïtat entre cohorts.

5. Discussió

5.1. Compliment dels objectius

L'objectiu principal d'aquest treball consistia en desenvolupar i validar un model predictiu robust de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble i metodològicament rigorós, amb capacitat de generalització en cohorts independents.

Aquest objectiu s'ha assolit parcialment en termes de rendiment predictiu, però de manera sòlida des d'un punt de vista metodològic.

En concret, el model desenvolupat ha mostrat una capacitat discriminativa moderada-alta en validació interna ($AUC \approx 0,83$), confirmant que és possible capturar un senyal transcriptòmic rellevant associat a la resposta a immunoteràpia. No obstant això, en validació externa, el rendiment disminueix ($AUC \approx 0,61-0,67$), evidenciant limitacions en la seva capacitat de generalització entre cohorts independents.

Aquest resultat indica que, tot i que el model compleix l'objectiu de capturar informació biològica rellevant, no assoleix plenament el requisit de transferibilitat clínica, que constituïa un element central de l'objectiu principal.

Pel que fa als objectius específics:

(1) Construcció del pipeline reproducible → assolit completament

S'ha desenvolupat un pipeline modular, traçable i completament reproducible, que integra totes les etapes de l'anàlisi i garanteix la separació estricta entre dades d'entrenament i test. Aquest objectiu es considera plenament complert.

(2) Harmonització i preparació de dades → assolit completament

La definició coherent de responders i non-responders segons criteris RECIST, juntament amb el control del moment temporal (pre-treatment), ha permès construir un escenari predictiu clínicament realista. Aquest objectiu s'ha assolit amb èxit.

(3) Desenvolupament del model predictiu → assolit completament

El model Random Forest implementat és capaç de capturar relacions complexes en dades transcriptòmiques i obtenir un rendiment robust en validació interna, complint així aquest objectiu.

(4) Validació rigorosa del model → assolit completament

La implementació de nested cross-validation i el control explícit del data leakage representen una de les principals fortaleces del treball, permetent obtenir estimacions realistes del rendiment. Aquest objectiu s'ha complert de manera sòlida.

(5) Validació externa i generalització → assolit parcialment

Tot i que el model mostra capacitat predictiva en cohorts independents, la variabilitat observada entre datasets indica una generalització limitada. Aquest objectiu s'ha assolit parcialment.

(6) Interpretació i robustesa biològica → assolit completament

L'anàlisi funcional i l'estabilitat de la signatura gènica confirmen la presència d'un senyal biològic coherent amb la literatura, complint aquest objectiu.

En conjunt, els resultats mostren que el treball compleix els objectius metodològics plantejats, però posa de manifest que el principal repte no és la construcció del model, sinó la seva capacitat de generalització en contextos clínics reals.

5.2. Compliment dels resultats

Els resultats obtinguts en aquest treball permeten avaluar de manera crítica tant la capacitat predictiva del model desenvolupat com la seva robustesa metodològica i biològica.

5.2.1. Resultats en validació interna

El model final, basat en una signatura de 100 gens i validat mitjançant *nested cross-validation*, presenta una capacitat discriminativa moderada-alta ($AUC \approx 0,83$), juntament amb valors consistents d'accuracy i *balanced accuracy*.

Aquests resultats indiquen que el model és capaç de capturar un senyal transcriptòmic real associat a la resposta a immunoteràpia. La utilització d'una estratègia lliure de *data leakage* reforça la validesa d'aquesta estimació, evitant la sobreestimació observada en fases preliminars del treball.

5.2.2. Impacte de la correcció del data leakage

Un dels resultats més rellevants del treball és la diferència observada entre el pipeline inicial i el model refinat.

Inicialment, es va obtenir un rendiment elevat ($AUC \approx 0,94$), que posteriorment es va reduir a valors més realistes ($AUC \approx 0,83$) després de corregir el *data leakage*. Aquesta reducció no representa una pèrdua de qualitat del model, sinó una millora en la seva validesa metodològica.

Aquest resultat posa de manifest la importància crítica del disseny experimental en models d'aprenentatge automàtic aplicats a dades òmiques, i constitueix una evidència clara del rigor del pipeline desenvolupat.

5.2.3. Impacte de la dimensionalitat de la signatura

L'anàlisi comparativa entre signatures de diferent mida (50, 100, 250 i 500 gens) mostra que una signatura de 100 gens proporciona el millor compromís entre rendiment i complexitat.

Aquest resultat és coherent amb el principi de parsimonia, indicant que la incorporació de més variables no implica necessàriament una millora del rendiment, sinó que pot introduir soroll i afavorir l'overfitting.

Aquesta anàlisi reforça la robustesa del model final seleccionat.

5.2.4. Resultats en validació externa

En validació externa, el model presenta una capacitat discriminativa moderada en GSE91061 (AUC $\approx$ 0,67) i limitada en GSE78220 (AUC $\approx$ 0,61), amb una variabilitat notable entre cohorts.

Aquest comportament reflecteix una generalització heterogènia, atribuïble a factors com:

- Diferències biològiques entre cohorts
- Variabilitat tècnica (plataformes, preprocessament)
- Mida mostral limitada

Tot i aquestes limitacions, els resultats confirmen l'existència d'un senyal predictiu transferible, encara que amb una magnitud moderada.

5.2.5. Anàlisi del comportament del model

L'anàlisi detallada de les mètriques mostra patrons rellevants:

- En GSE91061, el model manté un equilibri moderat entre sensibilitat (0,60) i especificitat (0,62).
- En GSE78220, es detecta un comportament esbiaixat cap a la classificació de non-responders, amb sensibilitat 0,00 i especificitat 1,00.

Aquest resultat suggereix que el model pot ser sensible a la distribució de classes i a les característiques específiques de cada cohort, aspecte crític en entorns clínics reals.

5.2.6. Robustesa i estabilitat de la signatura

L'anàlisi d'estabilitat de la selecció gènica mostra que existeix un subconjunt de gens consistentment seleccionats entre folds, indicant la presència d'un nucli transcriptòmic robust.

A més, tot i que l'anàlisi d'enriquiment funcional no va identificar termes significatius després de la correcció per múltiples contrastos, la inspecció dels gens prioritzats suggereix processos biològics coherents amb la literatura, com la regulació post-transcripcional, el RNA splicing i la resposta a estrès cel·lular. Aquest resultat reforça la plausibilitat biològica de la signatura, però s'ha d'interpretar com una hipòtesi exploratòria i no com una validació funcional definitiva.

5.2.7. Conclusió global dels resultats

En conjunt, els resultats obtinguts mostren que:

- El model és capaç de capturar un senyal transcriptòmic real associat a la resposta a immunoteràpia
- La seva capacitat predictiva és moderada i dependent del context del dataset
- El pipeline desenvolupat proporciona estimacions robustes i metodològicament fiables

Aquests resultats no només validen el model proposat, sinó que també evidencien les dificultats inherents a la generalització de signatures moleculars en cohorts independents, aspecte central en la bioinformàtica translacional.

5.3. Comparació amb la literatura

Els resultats obtinguts en aquest treball s'alineen de manera general amb la literatura actual sobre predicció de resposta a immunoteràpia en melanoma, tant pel que fa al rendiment dels models com a les dificultats associades a la seva generalització en cohorts independents.

Diversos estudis previs han desenvolupat signatures transcriptòmiques o models predictius orientats a identificar pacients amb més probabilitat de respondre a inhibidors de checkpoint immunitari. En general, aquests estudis solen mostrar rendiments elevats en validació interna, però una reducció del rendiment quan els models s'apliquen a cohorts externes. Aquesta disminució s'explica principalment per l'heterogeneïtat biològica entre pacients, les diferències tècniques entre plataformes d'expressió, la mida mostral limitada i la manca d'estandardització dels pipelines d'anàlisi.

En aquest context, el model desenvolupat en aquest treball presenta una AUC aproximada de 0,83 en validació interna mitjançant nested cross-validation i valors d'AUC entre 0,61 i 0,67 en validació externa. Aquests resultats són coherents amb el patró descrit a la literatura: el model és capaç de capturar un senyal transcriptòmic associat a la resposta a immunoteràpia, però la seva transferibilitat disminueix quan s'aplica a cohorts independents amb característiques tècniques i clíniques diferents.

Una diferència rellevant respecte a alguns estudis previs és l'èmfasi metodològic d'aquest treball. El pipeline incorpora un control explícit del data leakage, de manera que la selecció de variables, el preprocessament i l'entrenament del model es realitzen exclusivament dins de cada partició d'entrenament. Aquesta estratègia, juntament amb la validació creuada anidada, permet obtenir una estimació més realista del rendiment i evita valors artificialment inflats. La reducció observada entre el pipeline inicial i el model final reforça precisament la importància d'aquest control metodològic en dades òmiques d'alta dimensionalitat.

Des d'un punt de vista biològic, molts estudis previs en melanoma i immunoteràpia han destacat principalment signatures associades a activació immune, infiltració limfocitària, presentació antigènica, resposta a interferó i checkpoints immunitaris. Aquest treball és coherent amb aquest marc general, ja que també parteix de la hipòtesi que la resposta a immunoteràpia està condicionada pel microambient tumoral i per l'estat immunològic del tumor. No obstant això, els gens prioritzats pel model suggereixen també una capa addicional de regulació biològica, relacionada amb regulació post-transcripcional, RNA splicing, resposta a estrès cel·lular, autofàgia i proteòstasi.

Aquesta observació no contradiu les signatures immunitàries clàssiques, sinó que les complementa. Processos com el splicing alternatiu, la regulació de l'estabilitat dels transcrits o la resposta a estrès poden influir indirectament en la immunogenicitat tumoral, en la generació de variants proteiques, en la presentació d'antígens i en la capacitat de les cèl·lules tumorals per adaptar-se al tractament. En aquest sentit, gens com SRSF1, CRNKL1, ZFP36 o ATF3 permeten formular una hipòtesi segons la qual la resposta a immunoteràpia podria estar modulada no només per la presència d'un infiltrat immune actiu, sinó també per l'estat transcriptòmic i adaptatiu del tumor.

Aquesta interpretació, però, s'ha de fer amb cautela. El present treball no demostra un mecanisme biològic causal ni valida funcionalment els gens identificats. La selecció de variables es basa en diferències d'expressió i en la seva utilitat predictiva dins del model Random Forest, de manera que alguns gens poden actuar com a marcadors indirectes del context tumoral. Per tant, la comparació amb la literatura dona suport a la plausibilitat biològica dels resultats, però no substitueix la necessitat de validació independent i funcional.

Taula 5.1. Comparació qualitativa amb estudis previs sobre signatures transcriptòmiques i resposta a immunoteràpia en melanoma.

Estudi	Enfocament principal	Senyal biològic destacat	Relació amb aquest treball
Hugo et al. (2016)	Caracterització transcriptòmica i genòmica de resposta i resistència a anti-PD-1	Inflamació, resposta immune i mecanismes de resistència primària	Coincideix en la importància del context immune, però aquest treball afegeix una lectura centrada en regulació post-transcripcional i splicing
Riaz et al. (2017)	Evolució del tumor i del microambient durant el tractament amb nivolumab	Canvis dinàmics en el microambient tumoral i resposta immune	Aquest treball se centra en mostres pre-traitment, però comparteix la idea que la resposta depèn de l'estat molecular del tumor
Gide et al. (2019)	Caracterització del microambient immune en resposta a anti-PD-1 i anti-CTLA-4	Poblacions immunes, limfòcits T activats i microambient tumoral	Complementa aquest treball, que utilitza dades bulk RNA-seq i captura senyals transcriptòmics globals
Auslander et al. (2018)	Predictor transcriptòmic de resposta a immune checkpoint blockade	Relacions entre gens immunitaris i checkpoints	Comparteix l'objectiu predictiu, però aquest treball prioritza el control del data leakage i la validació externa
Aquest treball	Pipeline reproducible amb Random Forest i signatura final de 100 gens	Regulació post-transcripcional, RNA splicing, estrès cel·lular, autofàgia i proteòstasi	Aporta una prova de concepte metodològicament robusta i una hipòtesi biològica complementària

En conjunt, els resultats d'aquest treball confirmen dos missatges centrals de la literatura. En primer lloc, les dades transcriptòmiques contenen un senyal predictiu real relacionat amb la resposta a immunoteràpia. En segon lloc, la generalització d'aquest senyal entre cohorts independents continua sent el principal repte per a la translació clínica de les signatures moleculars. Així, més

enllà del rendiment predictiu concret, la principal aportació del treball rau en la implementació d'un pipeline bioinformàtic reproduïble i metodològicament rigorós, capaç d'avaluar de manera realista el potencial i les limitacions d'una signatura transcriptòmica en el context de la medicina de precisió.

5.4. Limitacions

Malgrat el rigor metodològic aplicat, aquest treball presenta diverses limitacions que cal considerar per interpretar adequadament els resultats i el seu potencial de transferència clínica.

En primer lloc, la mida mostral limitada constitueix una de les principals limitacions de l'estudi. Tot i que el dataset d'entrenament GSE160638 presenta una distribució equilibrada entre responders i non-responders, el nombre total de mostres continua sent reduït per a un problema d'alta dimensionalitat com l'anàlisi transcriptòmica. Aquesta limitació és encara més rellevant en les cohorts de validació externa, especialment en GSE78220, que inclou un nombre limitat de mostres. Com a conseqüència, les estimacions de rendiment poden presentar una variabilitat elevada i ser sensibles a petits canvis en la composició de les cohorts.

En segon lloc, existeix una heterogeneïtat important entre datasets, tant a nivell biològic com tècnic. Les cohorts utilitzades provenen d'estudis independents, amb possibles diferències en les característiques clíniques dels pacients, l'estadi de la malaltia, els protocols terapèutics, el moment de recollida de les mostres i la composició del microambient tumoral. Aquesta heterogeneïtat pot afectar la transferibilitat de la signatura molecular i explicar, almenys parcialment, la disminució del rendiment observada en validació externa.

En tercer lloc, cal considerar les diferències tècniques entre plataformes i formats d'expressió. Mentre que el dataset d'entrenament es va processar mitjançant una estratègia basada en TMM i logCPM, GSE78220 proporciona dades en format FPKM. Tot i que es van aplicar transformacions i procediments d'harmonització per fer comparables les dades, les diferències en escala, distribució i preprocessament poden introduir variabilitat tècnica residual. Aquest aspecte és especialment rellevant per interpretar el comportament del model en GSE78220, on es va observar una classificació predominant cap a non-responders, amb sensibilitat nul·la i especificitat màxima.

Un altre aspecte rellevant és l'absència d'una correcció explícita de batch effects entre cohorts. Tot i que s'ha aplicat una normalització independent per a cada dataset i s'ha restringit l'anàlisi a la intersecció de gens comuns, no s'ha implementat cap mètode de correcció inter-cohort com ComBat o *limma::removeBatchEffect*. Aquesta decisió es va prendre per evitar la introducció de biaixos artificials en un escenari de validació externa, on l'objectiu principal és avaluar la capacitat de generalització real del model sense modificar les dades de test amb informació conjunta entre cohorts. No obstant això, és possible que diferències tècniques residuals entre datasets hagin contribuït a la reducció del rendiment observada en validació externa.

En quart lloc, tot i l'esforç d'harmonització clínica, la definició de la resposta terapèutica pot no ser completament equivalent entre estudis. La classificació binària responders/non-responders es va establir a partir de criteris RECIST, considerant CR i PR com a resposta i SD i PD com a no resposta. Tanmateix, la categoria de malaltia estable pot incloure situacions biològicament heterogènies, fet que pot introduir soroll en la variable objectiu i afectar l'aprenentatge del model.

Des d'un punt de vista metodològic, tot i la implementació de nested cross-validation i el control explícit del data leakage, el risc de sobreajust no es pot eliminar completament. Aquest risc és inherent a l'anàlisi de dades òmiques, on el nombre de variables és molt superior al nombre de mostres. La selecció de variables dins de cada fold i la reducció de la signatura final a 100 gens contribueixen a minimitzar aquest problema, però no l'eliminen completament.

A més, l'ús de dades transcriptòmiques bulk limita la capacitat de capturar la heterogeneïtat cel·lular del microambient tumoral. Aquest tipus de dades reflecteix una mitjana global del senyal transcriptòmic de la mostra, però no permet distingir de manera precisa la contribució de diferents poblacions cel·lulars, com limfòcits T, cèl·lules mieloides, fibroblasts o cèl·lules tumorals. Aquesta limitació és especialment important en immunoteràpia, ja que la resposta al tractament depèn en gran mesura de la interacció entre el tumor i el sistema immunitari.

No obstant això, és important destacar que moltes d'aquestes limitacions han estat explícitament abordades dins del disseny del pipeline. En particular:

- S'ha implementat un control estricte del data leakage
- S'ha prioritzat la validació externa en cohorts independents
- S'ha restringit l'anàlisi a gens comuns entre datasets
- S'ha definit un escenari predictiu clínicament realista (pre-treatment)

Aquest enfocament permet que les limitacions identificades no invalidin els resultats, sinó que en contextualitzin correctament l'abast i reforcin la seva interpretació.

En aquest sentit, el treball no només posa de manifest les dificultats inherents a la predicció de resposta a immunoteràpia, sinó que també evidencia la importància d'un disseny metodològic rigorós per obtenir conclusions fiables.

5.5. Implicacions clíniques i ètiques

Els resultats d'aquest treball tenen implicacions rellevants en el context de la medicina de precisió, ja que la possibilitat de predir la resposta a immunoteràpia podria contribuir a una millor selecció de pacients, evitar tractaments ineficaços, reduir l'exposició a efectes adversos i optimitzar l'ús de recursos sanitaris.

Tanmateix, aquestes possibles aplicacions s'han d'interpretar amb prudència. El rendiment moderat observat en validació externa indica que el model encara no és aplicable directament en la pràctica clínica. En un context assistencial real, una classificació incorrecta podria tenir conseqüències importants. Un fals negatiu podria excloure un pacient d'un tractament potencialment beneficiós, mentre que un fals positiu podria afavorir l'administració d'un tractament ineficaç, amb toxicitat associada i retard en l'aplicació d'alternatives terapèutiques.

En termes clínics, una sensibilitat de 0,60, com l'observada en GSE91061, implicaria que aproximadament 4 de cada 10 pacients realment respondors podrien no ser identificats pel model. En un context assistencial, això seria especialment rellevant, ja que aquests pacients podrien quedar exclosos d'un tractament potencialment beneficiós si el model s'utilitzés de manera directa. Per tant, tot i que el rendiment és informatiu des d'un punt de vista exploratori, encara és insuficient per justificar una aplicació clínica individualitzada.

Per aquest motiu, el model desenvolupat no s'ha d'entendre com una eina de decisió clínica, sinó com una prova de concepte bioinformàtica orientada a explorar el potencial de signatures transcriptòmiques predictives. Qualsevol aplicació clínica requeriria validació prospectiva, avaluació en cohorts més grans i independents, integració amb variables clíniques i moleculars addicionals, i una anàlisi específica de seguretat, equitat i impacte assistencial.

Des d'un punt de vista ètic, també cal considerar possibles biaixos derivats de la mida mostral limitada, l'heterogeneïtat entre cohorts i la representativitat dels pacients inclosos en els datasets públics. Un model entrenat sobre cohorts reduïdes o no representatives podria tenir un rendiment desigual en diferents poblacions, fet que podria generar decisions clíniques inequitatives si s'utilitzés de manera prematura.

En conseqüència, la principal contribució clínica d'aquest treball no és proporcionar un model llest per a l'ús assistencial, sinó demostrar la importància d'avaluar de manera rigorosa la generalització, la robustesa i les limitacions dels models predictius abans de considerar-ne la translació a la pràctica mèdica.

5.6. Robustesa i reproductibilitat

Un dels principals punts forts d'aquest treball és l'èmfasi en la robustesa metodològica i la reproductibilitat del pipeline desenvolupat, aspectes fonamentals en el context de la bioinformàtica translacional.

En primer lloc, el disseny del pipeline garanteix una **separació estricta entre les dades d'entrenament i test en totes les etapes de l'anàlisi**, evitant qualsevol forma de *data leakage*. Aquest control s'implementa de manera sistemàtica, assegurant que tant la selecció de variables com el preprocessament i l'entrenament del model es realitzen exclusivament dins de cada partició d'entrenament.

A més, la utilització de **validació creuada anidada (nested cross-validation)** permet obtenir estimacions robustes i no esbiaixades del rendiment del model, integrant en un mateix marc la selecció de variables, l'optimització d'hiperparàmetres i l'avaluació final. Aquest enfocament representa una millora significativa respecte a aproximacions més simples i constitueix una de les aportacions metodològiques principals del treball.

Des del punt de vista de la reproductibilitat, el pipeline ha estat implementat seguint principis de **modularitat, traçabilitat i separació de fases**, amb una estructura clara entre dades, processament i resultats. Aquesta organització permet reproduir completament l'anàlisi, així com adaptar-lo fàcilment a nous datasets o escenaris clínics.

Adicionalment, l'anàlisi d'estabilitat de la signatura gènica mostra que, per a la signatura final de 100 gens, 29 gens van ser seleccionats en ≥ 4 folds i 13 gens en els cinc folds, suggerint l'existència d'un nucli reduït però consistent de gens associats al senyal predictiu.

No obstant això, els resultats de validació externa evidencien que la **robustesa interna del model no es tradueix completament en robustesa externa**, amb una variabilitat notable del rendiment entre cohorts. Aquest fet posa de manifest que el principal repte en aquest tipus de models no és la seva reproducció tècnica, sinó la seva capacitat de generalització en entorns biològicament i tècnicament heterogenis.

En aquest context, el pipeline desenvolupat constitueix una base sòlida i metodològicament fiable, alineada amb els principis de *reproducible research* i *open science*, i representa un pas rellevant cap a la seva futura aplicació en medicina de precisió.

En aquest sentit, els resultats d'aquest treball reforcen la idea que, en el context de la bioinformàtica translacional, el principal repte no és assolir un alt rendiment en validació interna, sinó garantir la seva transferibilitat en cohorts independents, aspecte que continua sent una limitació estructural en el desenvolupament de signatures moleculars.

6. Conclusions i treball futur

6.1. Conclusions

Aquest treball ha tingut com a objectiu desenvolupar i validar un model predictiu de resposta a immunoteràpia en melanoma basat en dades transcriptòmiques, mitjançant un pipeline bioinformàtic reproduïble i metodològicament rigorós.

Els resultats obtinguts permeten extreure diverses conclusions rellevants.

En primer lloc, s'ha demostrat la viabilitat de construir un pipeline complet que integra preprocessament, selecció de variables i modelització, incorporant bones pràctiques com el control explícit del *data leakage* i la validació creuada

anidada. Aquest enfocament constitueix una aportació metodològica clau, ja que permet obtenir estimacions realistes i fiables del rendiment del model.

En segon lloc, el model desenvolupat, basat en una signatura de 100 gens, és capaç de capturar un senyal transcriptòmic associat a la resposta a immunoteràpia, amb una capacitat discriminativa moderada-alta en validació interna (AUC $\approx$ 0,83) i moderada en validació externa (AUC entre 0,61 i 0,67).

En tercer lloc, els resultats evidencien que la resposta a immunoteràpia és un fenomen complex i multigènic, en què intervenen múltiples processos biològics, incloent la regulació post-transcripcional, el RNA splicing i la resposta a estrès cel·lular.

No obstant això, el treball també posa de manifest que el principal repte en aquest camp no és la construcció del model, sinó la seva capacitat de generalització en cohorts independents. La variabilitat observada en validació externa reflecteix la heterogeneïtat biològica i tècnica inherent a les dades transcriptòmiques.

En aquest sentit, aquest treball s'ha d'interpretar com una prova de concepte robusta, que demostra tant el potencial com les limitacions de les signatures moleculars en la predicció de la resposta a immunoteràpia.

6.1.1. Conclusió final

En conclusió, aquest TFM no només aporta un model predictiu, sinó també un marc metodològic sòlid per a l'anàlisi de dades òmiques en contextos clínics, posant en valor la importància de la reproductibilitat, el control del biaix i la validació rigorosa com a requisits essencials per a la transferència cap a la medicina de precisió.

6.2. Aportacions del treball

Aquest treball aporta contribucions rellevants tant des d'un punt de vista metodològic com aplicat, amb un èmfasi especial en la robustesa, la reproductibilitat i la validesa dels resultats en contextos reals.

6.2.1. Aportacions metodològiques

Des d'una perspectiva metodològica, destaca el desenvolupament d'un pipeline bioinformàtic completament reproduïble que integra bones pràctiques en l'anàlisi de dades òmiques. En particular, el treball incorpora:

- Control explícit del data leakage en totes les etapes del pipeline
- Implementació de validació creuada anidada (nested cross-validation)
- Separació estricta entre dades d'entrenament i test
- Validació externa en cohorts independents

Aquest conjunt d'estratègies permet obtenir estimacions realistes i no esbiaixades del rendiment del model, evitant la sobreestimació observada en aproximacions més simples.

Un dels aspectes més rellevants del treball és la identificació i correcció del problema de data leakage en el pipeline inicial. La reducció del rendiment observada després d'aquesta correcció no representa una pèrdua de qualitat, sinó una millora en la validesa metodològica, i posa de manifest la importància del disseny experimental en models predictius aplicats a dades transcriptòmiques.

A més, el pipeline ha estat dissenyat seguint principis de modularitat i traçabilitat, facilitant la seva reutilització i extensió a nous datasets o escenaris clínics.

6.2.2. Innovació del treball

Tot i que el treball no proposa un nou algoritme de classificació, la seva innovació rau en la definició d'un enfocament metodològic orientat a la generalització real dels models en bioinformàtica translacional.

En primer lloc, el pipeline ha estat dissenyat explícitament per simular un escenari clínic real, en què la predicció es basa exclusivament en dades pre-treatment i s'avalua en cohorts completament independents. Aquest enfocament contrasta amb molts estudis previs, centrats principalment en validació interna, i aporta una perspectiva més alineada amb la medicina de precisió.

En segon lloc, el treball introdueix un control sistemàtic i rigorós del data leakage, assegurant que la selecció de variables, el preprocessament i l'entrenament del model es realitzen exclusivament dins de cada partició d'entrenament. Aquesta estratègia garanteix que les estimacions de rendiment siguin realistes i transferibles, evitant resultats inflats.

En tercer lloc, es prioritza la validació externa en múltiples cohorts independents (GSE91061 i GSE78220), incorporant decisions metodològiques clau com la restricció a gens comuns entre datasets i l'evitació d'imputacions artificials. Aquest disseny permet avaluar de manera estricta la capacitat de generalització del model en escenaris heterogenis.

Adicionalment, el treball aporta una anàlisi sistemàtica de la dimensionalitat de la signatura gènica, comparant diferents configuracions (50, 100, 250 i 500 gens) i identificant una solució òptima basada en criteris de rendiment, robustesa i simplicitat. Aquesta aproximació reforça l'aplicabilitat pràctica del model i evita l'ús de signatures sobredimensionades.

Finalment, des d'un punt de vista biològic, el treball identifica processos menys explorats en aquest context, com la regulació post-transcripcional i el RNA splicing, aportant una visió complementària a les signatures clàssiques basades en activació immune.

En conjunt, la innovació d'aquest treball no resideix únicament en el model desenvolupat, sinó en la capacitat de construir un pipeline metodològicament

rigorós que permet una avaluació realista, reproduïble i transferible en el context de la predicció de resposta a immunoteràpia.

6.2.3. Aportació global

En conjunt, aquest treball constitueix una prova de concepte sòlida que demostra que és possible desenvolupar models predictius basats en dades transcriptòmiques amb un alt grau de rigor metodològic.

A diferència d'altres aproximacions centrades principalment en el rendiment predictiu, aquest treball posa un èmfasi explícit en la validesa dels resultats, la reproductibilitat i la capacitat de generalització, aspectes clau per a la seva futura aplicació en medicina de precisió.

Així, més enllà del model desenvolupat, la principal aportació del treball rau en l'establiment d'un marc metodològic robust per a l'anàlisi de dades òmiques en contextos clínics, alineat amb els principis de *reproducible research* i bioinformàtica translacional.

En aquest sentit, la innovació principal del treball no rau en el desenvolupament d'un nou model, sinó en la definició d'un pipeline orientat a la validació real i la generalització, aspecte sovint infrarepresentat en estudis previs.

6.3. Limitacions i treball futur

Malgrat els resultats obtinguts, aquest treball presenta diverses limitacions que obren línies clares de treball futur.

En primer lloc, la mida mostral és limitada, especialment en la validació externa, fet que pot afectar la robustesa de les estimacions i la capacitat de generalització del model.

En segon lloc, existeix una elevada heterogeneïtat entre cohorts, tant a nivell biològic com tècnic, incloent diferències en plataformes, preprocessament i definició clínica de la resposta. Aquest factor es configura com el principal repte per a la transferibilitat del model.

En tercer lloc, tot i el procés d'harmonització clínica, la definició de la resposta terapèutica pot no ser completament equivalent entre datasets, introduint una font potencial de biaix.

A més, l'ús de dades transcriptòmiques bulk limita la capacitat d'interpretar la contribució específica dels diferents tipus cel·lulars del microambient tumoral.

En aquest context, futures línies de treball haurien d'incloure:

- Validació en cohorts més grans i homogènies
- Desenvolupament i comparació d'estratègies de normalització inter-cohort més robustes, incloent mètodes com ComBat o `limma::removeBatchEffect`, per avaluar si poden reduir l'impacte dels batch effects sense comprometre la validesa de la validació externa
- Integració de dades multiòmiques (genòmica, epigenòmica, proteòmica)

- Incorporació de dades de *single-cell RNA-seq* per capturar la heterogeneïtat cel·lular
- Exploració de models més avançats o híbrids (ensemble, deep learning)
- Refinament de la selecció de variables incorporant criteris d'estabilitat i coneixement biològic

Finalment, per a una aplicació clínica real, serà imprescindible validar aquestes signatures en cohorts prospectives i en entorns clínics controlats.

6.4. Conclusió final

Aquest treball demostra que el desenvolupament de models predictius basats en dades transcriptòmiques requereix no només capacitat tècnica, sinó un rigor metodològic estricte orientat a la generalització.

Els resultats evidencien que el principal repte no és assolir un alt rendiment en validació interna, sinó garantir la seva transferibilitat en cohorts independents.

En aquest context, el pipeline desenvolupat constitueix una aportació sòlida, reproducible i alineada amb els principis de la bioinformàtica translacional i la medicina de precisió.

7. Glossari

AUC (Area Under the Curve)

Mesura de la capacitat discriminativa d'un model de classificació. Un valor proper a 1 indica un rendiment excel·lent, mentre que 0,5 correspon a classificació aleatòria.

Accuracy

Proporció de mostres correctament classificades respecte al total.

Balanced accuracy

Mitjana entre sensibilitat i especificitat. Especialment útil en datasets amb desbalanceig de classes.

Biomarcador molecular

Característica biològica mesurable (en aquest cas, expressió gènica) associada a un procés clínic, com la resposta a tractament.

Cross-validation (CV)

Estratègia de validació basada en particions del dataset per estimar el rendiment del model.

Data leakage

Error metodològic en què informació del conjunt de test s'utilitza indirectament durant l'entrenament, provocant una sobreestimació del rendiment.

Dataset (cohort)

Conjunt de dades d'expressió gènica i informació clínica associada.

Differential Expression (DE)

Anàlisi estadística per identificar gens amb diferències d'expressió significatives entre grups.

FPKM (Fragments Per Kilobase Million)

Mesura normalitzada d'expressió gènica utilitzada en dades RNA-seq processades.

Gene signature (signatura gènica)

Conjunt de gens seleccionats que permeten discriminar entre condicions biològiques o clíniques.

Immunoteràpia (anti-PD-1)

Tractament basat en la modulació del sistema immunitari per atacar cèl·lules tumorals.

Nested cross-validation

Estratègia de validació amb dos nivells (intern i extern) que permet optimitzar hiperparàmetres evitant data leakage.

Pipeline bioinformàtic reproducible

Flux de treball estructurat i documentat que permet reproduir tots els passos de l'anàlisi.

Random Forest

Algorisme d'aprenentatge automàtic basat en múltiples arbres de decisió combinats (ensemble learning).

RECIST (Response Evaluation Criteria in Solid Tumors)

Criteris estàndard per avaluar la resposta tumoral (CR, PR, SD, PD).

Responder / Non-responder

Classificació binària dels pacients segons la seva resposta al tractament.

RNA-seq

Tecnologia de seqüenciació que permet quantificar l'expressió gènica a nivell transcriptòmic.

TMM (Trimmed Mean of M-values)

Mètode de normalització per corregir diferències de composició en dades RNA-seq.

logCPM (log-counts per million)

Transformació logarítmica de les dades d'expressió per estabilitzar la variància.

Overfitting (sobreajust)

Situació en què el model s'adapta excessivament a les dades d'entrenament i perd capacitat de generalització.

8. Bibliografia

Articles científics

- Hugo, W., et al. (2016). Genomic and transcriptomic features of response to anti-PD-1 therapy in metastatic melanoma. *Cell*, 165(1), 35–44.
- Riaz, N., et al. (2017). Tumor and microenvironment evolution during immunotherapy with nivolumab. *Cell*, 171(4), 934–949.
- Gide, T. N., et al. (2019). Distinct immune cell populations define response to anti-PD-1 monotherapy and anti-PD-1/anti-CTLA-4 combined therapy. *Cancer Cell*, 35(2), 238–255.
- Auslander, N., et al. (2018). Robust prediction of response to immune checkpoint blockade therapy in metastatic melanoma. *Nature Medicine*, 24, 1545–1549.
- Liu, D., et al. (2019). Integrative molecular and clinical modeling of clinical outcomes to PD-1 blockade in patients with metastatic melanoma. *Nature Medicine*, 25(12), 1916–1927.
- Litchfield, K., et al. (2021). Meta-analysis of tumor- and T cell-intrinsic mechanisms of sensitization to checkpoint inhibition. *Cell*, 184(3), 596–614.
- Chowell, D., et al. (2022). Improved prediction of immune checkpoint blockade efficacy across multiple cancer types. *Nature Biotechnology*, 40, 499–506.
- Johannet, P., et al. (2021). Using machine learning algorithms to predict immunotherapy response in patients with advanced melanoma. *Clinical Cancer Research*, 27(1), 131–140.
- Han, N., & Liu, Z. (2023). Targeting alternative splicing in cancer immunotherapy. *Frontiers in Cell and Developmental Biology*, 11, 1232146. <https://doi.org/10.3389/fcell.2023.1232146>
- Chen, W., Geng, D., Chen, J., Han, X., Xie, Q., Guo, G., Chen, X., Zhang, W., Tang, S., & Zhong, X. (2024). Roles and mechanisms of aberrant alternative splicing in melanoma: Implications for targeted therapy and immunotherapy resistance. *Cancer Cell International*, 24, 101. <https://doi.org/10.1186/s12935-024-03280-x>
- Lu, S. X., De Neef, E., Thomas, J. D., Sabio, E., Rousseau, B., Gigoux, M., Knorr, D. A., Greenbaum, B., Elhanati, Y., Hogg, S. J., Chow, A., Ghosh, A., Xie, A., Zamarin, D., Cui, D., Erickson, C., Singer, M., Cho, H., Wang, E., & Lu, B. (2021). Pharmacologic modulation of RNA splicing enhances anti-tumor immunity. *Cell*, 184(15), 4032–4047.e31. <https://doi.org/10.1016/j.cell.2021.05.038>

Metodologia bioinformàtica i estadística

- Robinson, M. D., McCarthy, D. J., & Smyth, G. K. (2010). *edgeR: a Bioconductor package for differential expression analysis of digital gene expression data*. *Bioinformatics*, 26(1), 139–140.

- Breiman, L. (2001). *Random Forests*. **Machine Learning**, 45(1), 5–32.
- Kuhn, M. (2008). *Building Predictive Models in R Using the caret Package*. **Journal of Statistical Software**, 28(5).
- Fawcett, T. (2006). *An introduction to ROC analysis*. **Pattern Recognition Letters**, 27(8), 861–874.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Sandve, G. K., et al. (2013). Ten simple rules for reproducible computational research. *PLOS Computational Biology*, 9(10).

Bases de dades utilitzades

- Edgar, R., Domrachev, M., & Lash, A. E. (2002). Gene Expression Omnibus: NCBI gene expression and hybridization array data repository. *Nucleic Acids Research*, 30(1), 207–210.
- Gene Expression Omnibus (GEO), NCBI
<https://www.ncbi.nlm.nih.gov/geo/>
 - o GSE160638
 - o GSE91061
 - o GSE78220

Paquets i eines de software

- R Core Team (2024). *R: A Language and Environment for Statistical Computing*.
<https://www.r-project.org/>
- Bioconductor Project
<https://www.bioconductor.org/>
- Paquets utilitzats:
 - o edgeR
 - o randomForest
 - o caret
 - o pROC
 - o clusterProfiler
 - o org.Hs.eg.db
 - o ggplot2

Referències conceptuals

- Topalian, S. L., et al. (2012). *Safety, activity, and immune correlates of anti-PD-1 antibody in cancer*. **New England Journal of Medicine**, 366(26), 2443–2454.
- Hanahan, D. (2022). *Hallmarks of Cancer: New Dimensions*. **Cancer Discovery**, 12(1), 31–46.
- Hegde, P. S., & Chen, D. S. (2020). Top 10 challenges in cancer immunotherapy. *Immunity*, 52(1), 17–35.

9. Annexos

9.1. Repositori GitHub del pipeline

El codi font complet del pipeline bioinformàtic desenvolupat en aquest treball, juntament amb els scripts modulars, els fitxers de resultats i les figures generades, es troba disponible en el següent repositori públic de GitHub:

<https://github.com/jcarrerasdi/melanoma-immunotherapy-response-pipeline>

Aquest repositori permet reproduir les principals etapes de l'anàlisi, incloent la càrrega i harmonització de dades, el preprocessament transcriptòmic, la selecció de variables, l'entrenament del model Random Forest, la validació interna, la validació externa i l'anàlisi d'estabilitat gènica.

9.2. Arquitectura del pipeline bioinformàtic

El pipeline desenvolupat en aquest treball s'ha dissenyat seguint principis de **modularitat, traçabilitat i reproductibilitat**, amb l'objectiu de garantir la seva reutilització en futurs estudis i en entorns clínics reals.

L'arquitectura del projecte es basa en una separació clara entre dades, processament i resultats, estructurada de la següent manera:

```
TFM_immunotherapy
├── data_processed
├── data_raw
├── figures
├── README.md
├── results
├── scripts
│   ├── 01_load_data.R
│   ├── 02_preprocessing.R
│   ├── 03_exploratory_analysis.R
│   ├── 04_differential_expression.R
│   ├── 05_model_training_nestedCV.R
│   ├── 06_external_validation.R
│   └── 07_gene_stability_analysis.R
```

Aquesta organització permet:

- Separació estricta entre dades originals i dades processades
- Traçabilitat completa de cada pas de l'anàlisi
- Execució modular del pipeline
- Facilitat d'extensió a nous datasets

Aquest disseny és coherent amb les bones pràctiques en bioinformàtica i evita dependències implícites entre fases.

9.3. Entorn computacional i dependències

L'anàlisi s'ha desenvolupat íntegrament en **R**, utilitzant eines de l'ecosistema CRAN i Bioconductor.

Configuració de l'entorn:

- Sistema operatiu: macOS
- R: versió 4.5.1
- Bioconductor: versió compatible amb R utilitzat

Paquets principals:

Categoria	Paquet	Funció
Preprocessament	edgeR	Filtrat i normalització RNA-seq
Modelització	randomForest	Classificador
Validació	caret	Cross-validation i tuning
Avaluació	pROC	Corbes ROC i AUC
Visualització	ggplot2	Figures
Anàlisi funcional	clusterProfiler	Enriquiment
Anotació	Org.Hs.eg.db	Mapping gènic

Aquest conjunt de dependències permet cobrir tot el flux d'anàlisi, des de dades crues fins a interpretació biològica.

9.4. Descripció formal del pipeline

El pipeline implementat segueix una seqüència estructurada de passos:

1. Obtenció i curació de dades

- Descàrrega de datasets des de GEO
- Extracció i alineació de metadades
- Curació de la variable resposta

2. Harmonització clínica

- Definició unificada de responders (CR/PR) i non-responders (SD/PD)
- Exclusió de casos amb informació ambigua
- Control explícit del moment temporal (pre-treatment)

3. Preprocessament transcriptòmic

- Filtrat de gens amb baixa expressió (*filterByExpr*)
- Normalització TMM
- Transformació logCPM

4. Selecció de variables

- Anàlisi d'expressió diferencial (edgeR GLM QL)
- Rànquing de gens segons significació
- Selecció dinàmica dins de cada fold

5. Modelització

- Entrenament amb Random Forest

- Optimització de *mtry* via validació interna

6. Validació

- Nested cross-validation
- Control estricte de data leakage

7. Validació externa

- Harmonització de datasets externs
- Intersecció de gens comuns
- Aplicació directa del model

8. Avaluació

- AUC
- Accuracy
- Balanced accuracy
- Sensibilitat / Especificitat

9. Interpretació

- Importància de variables
- Anàlisi funcional (GO, KEGG, Reactome)

Aquest disseny garanteix una separació estricta entre entrenament i test en totes les etapes.

9.5. Control del data leakage

Un dels aspectes clau del pipeline és el control explícit del **data leakage**, implementat mitjançant:

- Selecció de gens dins de cada fold
- Normalització independent per partició
- Separació estricta train/test
- Nested cross-validation

Aquest enfocament assegura que:

■ Cap informació del conjunt de test influeix en la construcció del model

Aquest punt és crític i constitueix una de les principals aportacions metodològiques del treball.

9.6. Implementació del model

El model predictiu es basa en Random Forest, amb la següent configuració general:

```

1 set.seed(123)
2
3 model <- randomForest(
4   x = train_data,
5   y = as.factor(train_labels),
6   ntree = 500,
7   mtry = tuned_mtry,
8   importance = TRUE
9 )

```

Característiques del model:

- Capacitat per manejar alta dimensionalitat
- Robustesa davant soroll
- Captura de relacions no lineals
- Estabilitat mitjançant agregació

Aquest model és especialment adequat per dades transcriptòmiques.

9.7. Estratègia d'intersecció de gens

Per garantir la coherència entre cohorts:

- Es defineix un espai comú de gens
- S'eliminen gens absents en datasets externs
- No s'utilitza imputació artificial

Aquest enfocament:

- Evita biaixos
- Manté consistència biològica
- Millora la interpretabilitat

9.8. Anàlisi d'estabilitat de la signatura

La robustesa de la selecció gènica s'ha avaluat mitjançant:

- Freqüència de selecció per fold
- Identificació de gens consistents
- Comparació de signatures alternatives

Aquest anàlisi permet:

- Detectar un nucli transcriptòmic robust
- Reduir dependència del dataset

- Millorar interpretabilitat biològica

9.9. Materials suplementaris

Els següents materials estan disponibles com a suport:

- Resultats complets d'expressió diferencial
- Llistat complet de gens seleccionats
- Resultats detallats de validació
- Figures addicionals (PCA, ROC, heatmaps)

Aquest conjunt permet una revisió exhaustiva dels resultats.

9.10. Reproductibilitat i reutilització

El pipeline desenvolupat garanteix:

- Reproducció completa dels resultats
- Modularitat del codi
- Facilitat d'adaptació a nous datasets
- Traçabilitat de decisions

Aquest enfocament s'alinea amb els principis de:

- **Reproducible research**
- **Open science**
- **Bioinformàtica translacional**

9.11. Limitacions tècniques del pipeline

Tot i el rigor metodològic, el pipeline presenta algunes limitacions:

- Dependència de la qualitat de les metadades
- Heterogeneïtat entre cohorts
- Limitacions de dades bulk RNA-seq
- Absència d'integració multiòmica

Aquestes limitacions constitueixen oportunitats de millora futura.